

GUIA DE ESTUDO COMPLETO

Governança de Dados

Trilha de aprendizado em dez capítulos, do conceito à operação ágil

- 1 · Introdução à governança de dados
- 2 · Governança e gestão na prática
- 3 · Big Data e Normal Data
- 4 · Metadados
- 5 · Linhagem de dados
- 6 · Qualidade dos dados
- 7 · Ética e privacidade
- 8 · Agilidade e governança (DAD e SAFe)
- 9 · Monitoramento contínuo
- 10 · Visuais para KPIs e OKRs (apoio)

Material de estudo elaborado a partir de conceitos e fontes públicas (DAMA-DMBOK, LGPD, ISO/IEC 25012, OpenLineage, PMI Disciplined Agile e SAFe). Não é um resumo do conteúdo do livro de Carlos Barbieri: as explicações são genéricas e não refletem o que o autor defende em cada capítulo.

Como usar este guia

Este guia reúne, em uma única trilha, o material de aprofundamento sobre governança de dados para quem vem da engenharia: **dez capítulos** organizados na ordem em que os conceitos se apoiam uns nos outros. Cada capítulo traz contexto, exemplos, tabelas, ilustrações e, no final, ideias de indicadores para o seu dashboard.

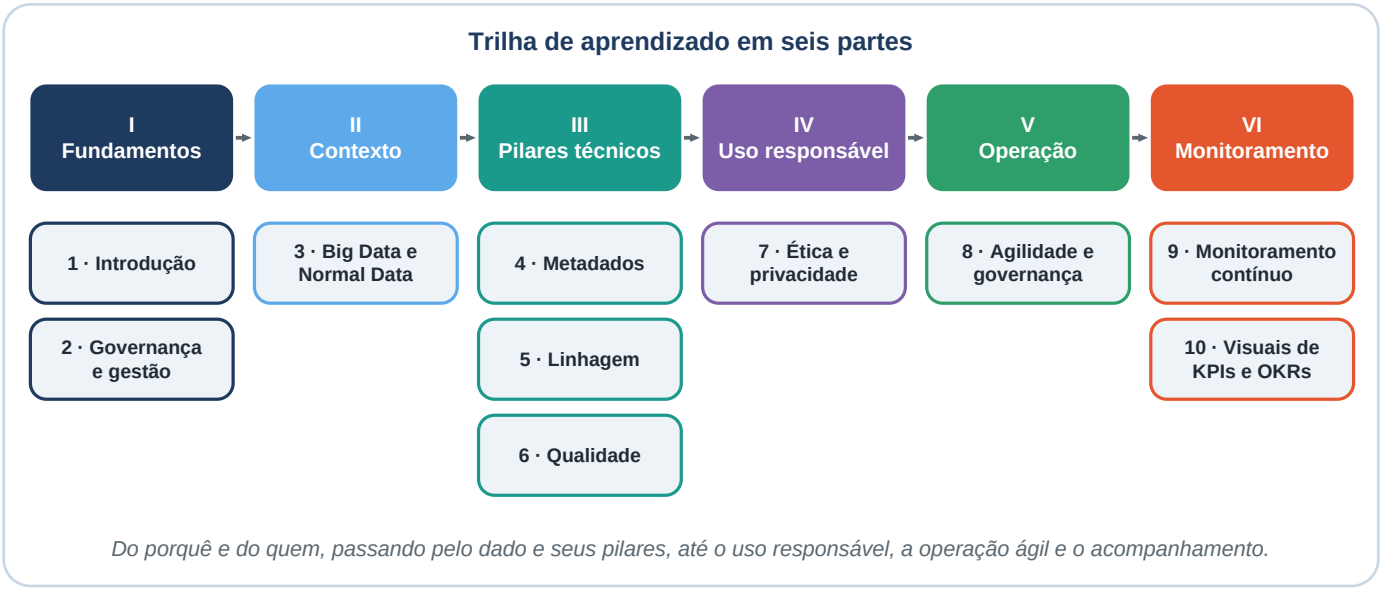


Figura 1 — A trilha em seis partes. Os capítulos 4, 5 e 6 podem ser lidos em qualquer ordem entre si, mas todos pedem os três primeiros. O capítulo 10 é de apoio ao 9.

Cap.	Tema	Por que nesta posição	Pré-requisito
1	Introdução à governança	Define o vocabulário, os componentes e os modelos que dão sentido ao resto	Nenhum
2	Governança e gestão na prática	Apresenta quem decide o quê: papéis, RACI, fóruns e escalonamento	Cap. 1
3	Big Data e Normal Data	Mostra o terreno onde os dados vivem e por que governá-los muda de escala	Caps. 1 e 2
4	Metadados	É a base técnica: sem metadados não há catálogo, linhagem nem qualidade visível	Caps. 1 a 3
5	Linhagem de dados	Usa os metadados para mostrar o caminho do dado e o impacto das mudanças	Cap. 4
6	Qualidade dos dados	Mede a confiabilidade; usa linhagem para achar causas e impactos	Caps. 4 e 5
7	Ética e privacidade	Depois de conhecer os mecanismos técnicos, olha para o uso responsável dos dados	Caps. 4 a 6
8	Agilidade e governança (DAD e SAFe)	Integra tudo: como operar a governança em ritmo ágil e em escala	Caps. 1 a 7
9	Monitoramento contínuo	Mantém a governança viva: uso, políticas, ownership, qualidade, sensibilidade e maturidade	Todos os anteriores
10	Visuais para KPIs e OKRs (apoio)	Exemplos de painéis e modelo de dados para acompanhar o que o capítulo 9 define	Cap. 9

Correspondência com o livro: os capítulos 1, 2, 3, 4, 6 e 7 deste guia equivalem aos capítulos 2, 3, 4, 7, 8 e 6 do sumário do livro; o capítulo 5 complementa o de metadados; o capítulo 8 corresponde ao de agilidade (cap. 9 do sumário); e os capítulos 9 e 10 são complementos deste guia, sem correspondente direto no sumário. Este material foi construído a partir de conceitos e referências públicas (DAMA-DMBOK, LGPD, ISO/IEC 25012, OpenLineage, PMI Disciplined Agile, SAFe) e **não reproduz nem resume o que o autor escreve** em cada capítulo. Exemplos numéricos e cenários são fictícios.

PARTE I · FUNDAMENTOS · CAP. 2 DO SUMÁRIO

1 Introdução à governança de dados

O problema que a governança resolve

Toda organização que cresce acumula sistemas, planilhas, bases e relatórios. Sem regras comuns, os mesmos dados passam a existir em versões diferentes, com significados diferentes. Um exemplo clássico: três áreas calculam "cliente ativo" de três formas, e a diretoria recebe três números para a mesma pergunta. Ninguém errou sozinho; faltou uma decisão compartilhada sobre o que o termo significa e quem pode mudá-lo.

Esse tipo de problema costuma aparecer em quatro frentes ao mesmo tempo:

- **Confiança:** relatórios divergentes e tempo gasto discutindo números em vez de decisões.
- **Risco e conformidade:** não saber onde estão os dados pessoais, quem acessa e por quanto tempo são guardados.
- **Eficiência:** equipes refazendo as mesmas extrações, limpezas e definições.
- **Valor:** projetos de analytics e IA travados por dados que ninguém sabe se pode usar.

O que é governança de dados

Em termos amplos, governança de dados é o conjunto de **decisões, responsabilidades, regras e controles** que determinam como os dados são definidos, protegidos, usados e descartados. A referência mais usada no mercado, o DAMA-DMBOK, descreve-a como o exercício de autoridade e controle (planejar, monitorar e fazer cumprir) sobre a gestão dos ativos de dados.

Uma forma prática de lembrar: governança define *o que deve acontecer e quem responde por isso*; a gestão faz acontecer. Veja as cinco perguntas que ela precisa responder:

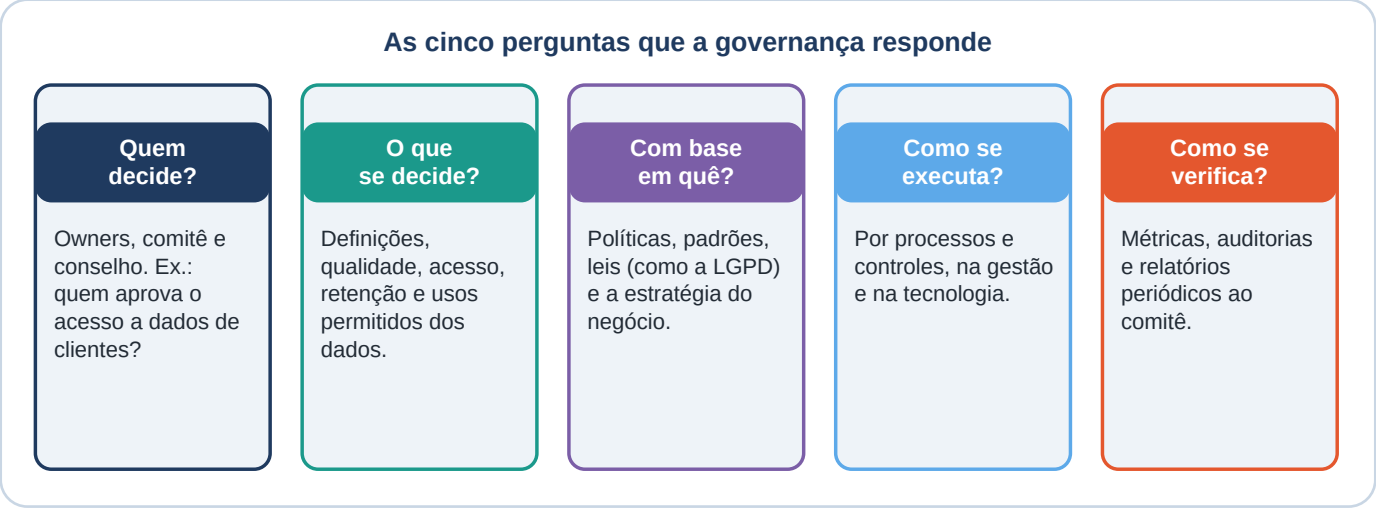


Figura 2 — As cinco perguntas de uma governança funcional. Se uma delas não tem resposta, existe uma lacuna.

Não confunda com disciplinas vizinhas

Disciplina	Foco principal	Relação com governança de dados
Governança corporativa	Direção e controle da organização como um todo	A governança de dados é parte dela e responde às mesmas instâncias de decisão.
Governança de TI	Uso e valor da tecnologia	Trata de sistemas; a de dados trata do conteúdo e do seu uso, independentemente do sistema.
Segurança da informação	Proteger confidencialidade, integridade e disponibilidade	Implementa controles; a governança define o que precisa de proteção e por quê.

Disciplina	Foco principal	Relação com governança de dados
Privacidade (LGPD)	Direitos do titular e tratamento lícito de dados pessoais	Depende da governança para inventário, classificação e rastreabilidade.
Gestão de dados	Executar arquitetura, integração, qualidade, etc.	Executa o que a governança decide e fiscaliza.

Componentes de um programa

Programas de governança diferem de empresa para empresa, mas quase sempre combinam os mesmos blocos:

- **Estratégia e valor:** por que a governança existe e quais resultados ela persegue (ex.: reduzir risco de LGPD, acelerar analytics).
- **Estrutura organizacional:** patrocinador, conselho ou comitê, escritório de governança, owners e stewards.
- **Políticas e padrões:** regras escritas e aprovadas sobre classificação, qualidade, acesso, retenção e uso.
- **Processos:** como resolver incidentes, aprovar acessos, mudar definições e tratar exceções.
- **Tecnologia:** catálogo, linhagem, monitoramento de qualidade, controle de acesso e automações que sustentam o resto.
- **Métricas:** indicadores que mostram progresso e dão visibilidade ao patrocinador.
- **Gestão da mudança:** comunicação, treinamento e incentivos, porque governança é, no fundo, mudança de comportamento.

Modelos de implantação

Não existe um único desenho correto. A escolha depende da cultura, do tamanho e da maturidade da empresa. Em geral, discute-se um espectro entre concentrar decisões em um time central ou distribuí-las pelos domínios de negócio:

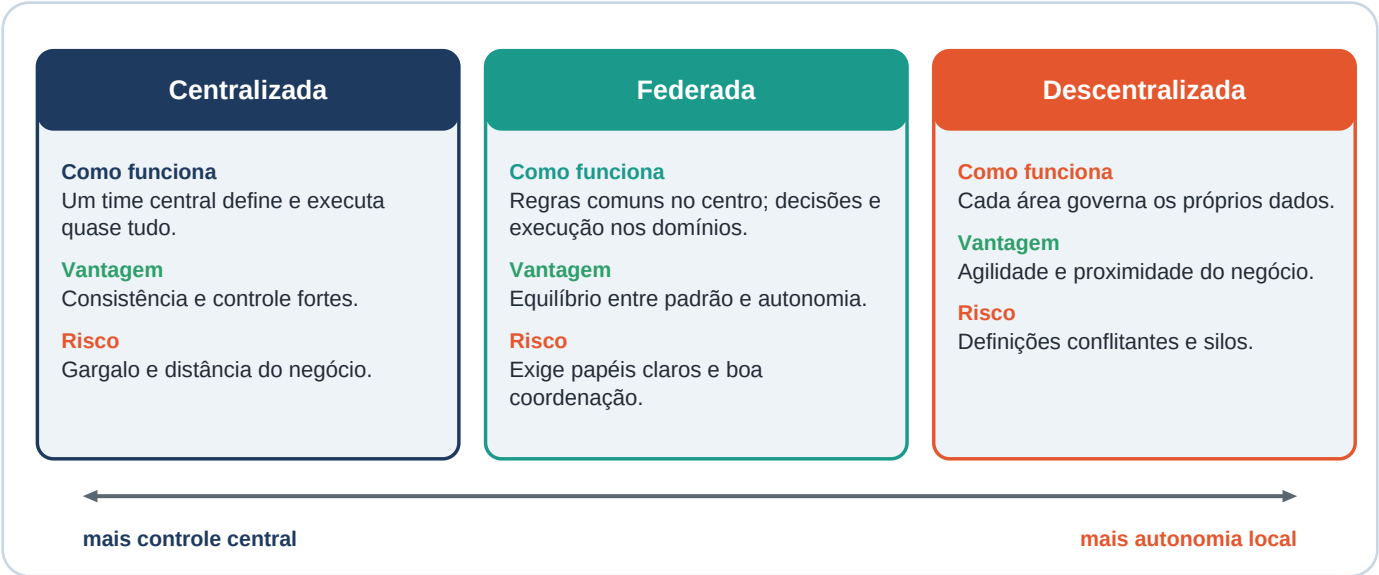


Figura 3 — Três modelos de organização. A abordagem federada é a mais citada atualmente: regras comuns, execução nos domínios.

Existe ainda a chamada **abordagem não invasiva**, popularizada por Robert Seiner: em vez de criar papéis do zero, reconhece-se que as pessoas já tomam decisões sobre dados e formaliza-se o que elas já fazem, reduzindo resistência e acelerando a adoção.

Maturidade: onde sua organização está?

Modelos de maturidade (como DAMA, DCAM e CMMI-DMM) ajudam a responder a pergunta "em que estágio estamos e qual é o próximo passo realista?". Em linhas gerais, a evolução costuma ser esta:

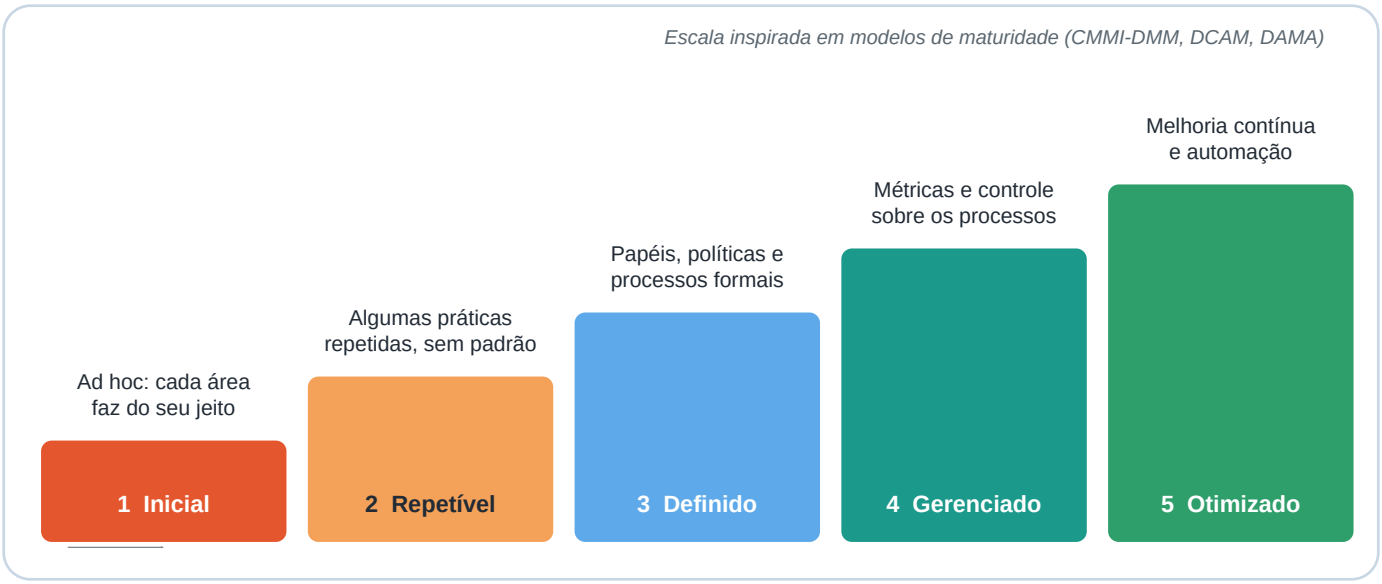


Figura 4 — Escada de maturidade. O objetivo não é chegar ao nível 5 em tudo, e sim ao nível adequado para o risco e o valor de cada domínio.

Como começar: um roteiro realista

- **1. Diagnóstico enxuto:** mapear dores concretas (relatórios divergentes, incidentes, pedidos de titulares) e onde estão os dados mais críticos.
- **2. Patrocínio e caso de uso:** escolher um problema com valor visível e um executivo que o defenda. Evite começar tentando governar tudo.
- **3. Papéis mínimos:** nomear owners e stewards do domínio piloto e criar um fórum de decisão com agenda regular.
- **4. Regras essenciais:** glossário dos termos críticos, política de classificação e padrão de qualidade para o piloto.
- **5. Medir e comunicar:** definir poucos indicadores, mostrar resultados e ajustar.
- **6. Escalar em ondas:** repetir o ciclo em novos domínios, incorporando o que foi aprendido.

Fatores de sucesso e erros comuns

Funciona bem	Costuma dar errado
Patrocínio executivo ativo e visível	Tratar governança como projeto de TI com data para acabar
Começar por um problema de negócio concreto	Começar comprando uma ferramenta, sem papéis nem regras
Papéis com tempo e autoridade reais	Nomear stewards "de nome", sem horas dedicadas
Automatizar controles sempre que possível	Depender só de planilhas, e-mails e reuniões
Medir resultados (não só atividades)	Medir apenas quantidade de políticas ou reuniões

Para quem vem da engenharia: o seu maior ativo é transformar regras em controles automáticos. Mas lembre que o controle só faz sentido se alguém com autoridade decidiu a regra. Se você está implementando algo sem saber quem aprovou e por quê, falta uma peça de governança.

PARTE I · FUNDAMENTOS · CAP. 3 DO SUMÁRIO

2

Governança e gestão de dados na prática

Governança e gestão: quem faz o quê

A distinção entre governança e gestão é simples no conceito, mas fácil de confundir no dia a dia. Pense numa empresa de transporte: a diretoria define quais rotas atender, quais normas de segurança seguir e quanto investir (governança); as equipes de operação conduzem os veículos, fazem manutenção e cumprem a escala (gestão). Uma sem a outra não funciona: regras sem execução ficam no papel e execução sem regras gera improviso.

Tema	Governança (decide e fiscaliza)	Gestão (executa e opera)
Qualidade de dados	Define dimensões, limites aceitáveis e responsáveis	Cria regras, mede, corrige e monitora
Segurança e acesso	Define quem pode acessar o quê e sob quais condições	Configura perfis, mascaramento e logs de auditoria
Metadados	Define o que deve ser documentado e quem aprova definições	Coleta, armazena e publica metadados no catálogo
Retenção	Define por quanto tempo cada tipo de dado é guardado	Implementa rotinas de arquivamento e descarte
Arquitetura	Aprova padrões e princípios	Projeta e implanta as soluções

Três níveis de decisão

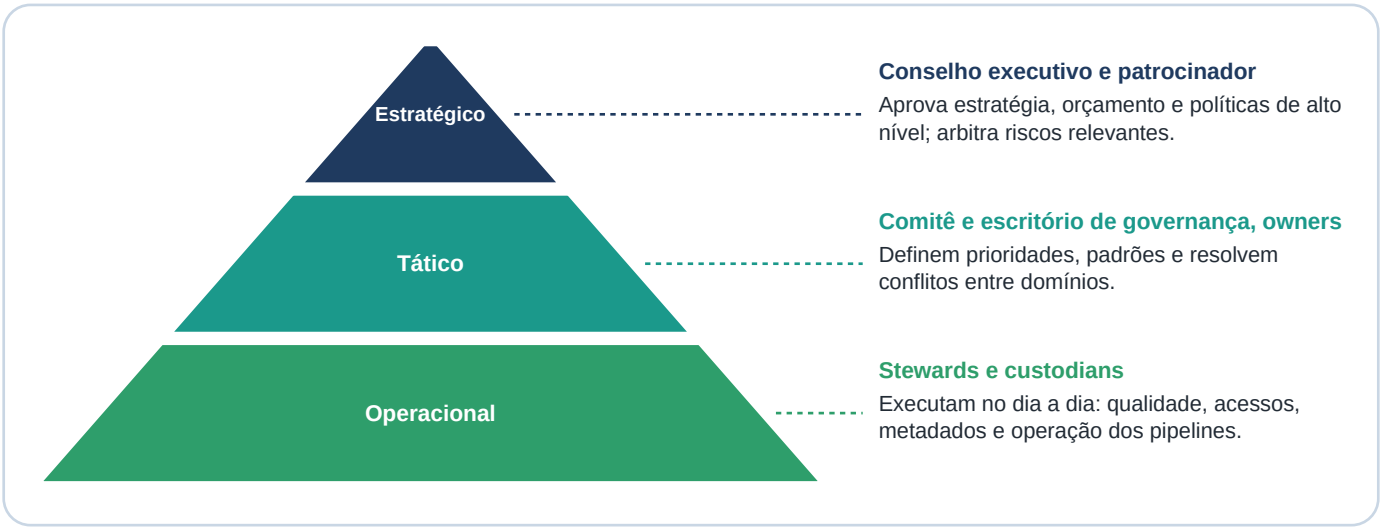


Figura 5 — Os três níveis de uma estrutura de governança. Quanto mais alto, menos frequente e mais estratégico é o assunto.

Essa separação evita dois problemas comuns: decisões operacionais chegando ao conselho (o que paralisa) e decisões estratégicas tomadas por quem apenas opera (o que gera incoerência).

Papéis e responsabilidades

Os nomes variam entre organizações, mas as responsabilidades se repetem. O importante é que cada responsabilidade tenha um dono identificável.

Papel	Responsabilidade principal	Exemplo de decisão
Patrocinador	Dá apoio executivo, orçamento e prioridade ao programa	Aprovar o plano e os recursos do programa

Papel	Responsabilidade principal	Exemplo de decisão
Conselho / comitê de governança	Aprova políticas, resolve conflitos e acompanha métricas	Decidir qual das duas definições de "cliente ativo" prevalece
Data owner	Responde pelo domínio: valor, risco e uso permitido dos dados	Autorizar o compartilhamento de dados do domínio com outra área
Data steward	Cuida de definições, regras e qualidade no dia a dia	Propor a definição de um termo e acompanhar incidentes de qualidade
Data custodian	Opera a tecnologia que guarda e movimenta os dados	Implementar o controle de acesso aprovado
Escritório de governança	Coordena o programa, a agenda, os indicadores e a comunicação	Consolidar o relatório mensal para o comitê
DPO / encarregado	Canal de privacidade com titulares e ANPD; orienta a conformidade	Opinar sobre a base legal de um novo tratamento
Consumidor de dados	Usa os dados respeitando as regras e reporta problemas	Abrir chamado ao identificar um dado incorreto

Atenção ao papel de custodian: no dia a dia, engenheiros de dados costumam estar neste papel. Isso quer dizer que a regra de negócio e a decisão de acesso não são suas, e sim do owner. Seu papel é executar com fidelidade, apontar riscos técnicos e registrar o que foi feito.

RACI: deixando as responsabilidades explícitas

A matriz RACI é uma ferramenta simples para evitar o "dado sem dono". Para cada atividade, define-se quem executa (R), quem responde pelo resultado (A, um só), quem é consultado (C) e quem apenas é informado (I).

Exemplo de matriz RACI (um único A por atividade)

Atividade	Owner	Steward	Custodian	Comitê	DPO
Definir termo no glossário	A	R	C	I	-
Aprovar acesso a dado sensível	A	C	R	-	C
Corrigir problema de qualidade	A	C	R	I	-
Definir regra de retenção	R	C	C	A	C
Aprovar política de dados	C	C	C	A	C

R executa · A responde pelo resultado · C é consultado · I é informado

Figura 6 — Exemplo ilustrativo de RACI. Cada organização ajusta a matriz à sua estrutura; o essencial é haver um único A por linha.

Fóruns, cadência e escalonamento

Estruturas de governança precisam de rotina. Fóruns sem pauta ou sem poder de decisão viram reuniões de status. Um desenho comum:

- **Conselho executivo** (trimestral ou semestral): estratégia, orçamento, riscos relevantes e resultados.
- **Comitê de governança** (mensal): prioridades, padrões, decisões entre domínios e acompanhamento de indicadores.

- **Grupos de domínio** (quinzenal ou semanal): owners e stewards tratando de definições, regras e incidentes do seu domínio.

Ao lado dos fóruns, é preciso um caminho claro para que um problema suba de nível apenas quando necessário:

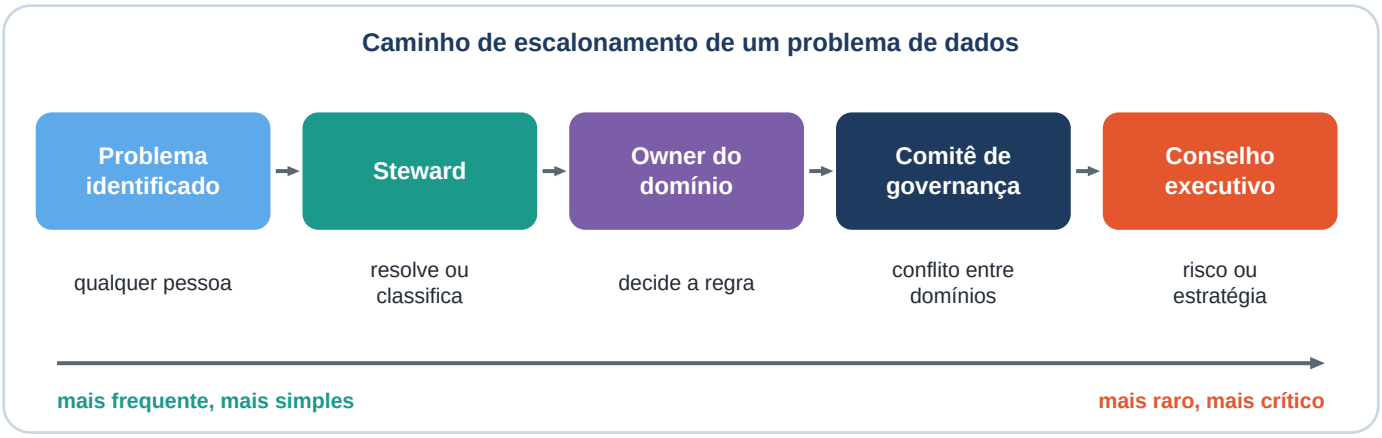


Figura 7 — Escalonamento. A maioria dos problemas deve ser resolvida pelo steward ou pelo owner, sem chegar ao comitê.

Domínios de dados

Para distribuir responsabilidades, a governança costuma organizar os dados em **domínios**, agrupamentos com sentido de negócio (cliente, produto, financeiro, pessoas, risco). Cada domínio tem um owner e um ou mais stewards. Organizar por domínio de negócio, e não por sistema, evita que a responsabilidade se perca quando um sistema é substituído.

Rotinas operacionais que dão vida ao modelo

- **Gestão de incidentes de dados:** registro, classificação por severidade, responsável, prazo e causa raiz.
- **Gestão de mudança em definições:** proposta, análise de impacto (usando linhagem), aprovação do owner e comunicação.
- **Gestão de acessos:** solicitação, aprovação do owner, revisão periódica e revogação.
- **Gestão de exceções:** pedido formal, justificativa, prazo e aprovação por quem tem autoridade.
- **Revisão de políticas:** ciclo periódico com histórico de versões.

Armadilhas frequentes

- Owner indicado, mas sem poder de decisão ou sem saber que tem esse papel.
- Stewards acumulando a função sem horas reservadas, o que faz o programa depender de heroísmo.
- Comitê que só informa, sem deliberar nem registrar decisões.
- Matriz de papéis desatualizada após reorganizações.
- Confundir o papel de owner com o de TI: dono do dado é o negócio.

3 Governança de dados: Big Data e Normal Data

Dois mundos de dados

Chamamos aqui de **normal data** os dados tradicionais das organizações: transacionais, estruturados, vindos de sistemas conhecidos (ERP, CRM, financeiro) e consolidados em bancos relacionais e data warehouses. Já o **Big Data** designa conjuntos de dados tão grandes, rápidos ou variados que as técnicas tradicionais têm dificuldade de armazená-los e processá-los.

A caracterização mais conhecida vem dos "Vs". O analista Doug Laney propôs em 2001 três deles (volume, velocidade e variedade); depois, o mercado acrescentou veracidade (confiabilidade) e valor. Eles não são uma definição exata, mas ajudam a entender onde a governança sofre mais.

Dimensão	Normal data	Big Data
Origem	Sistemas internos conhecidos	Internas e externas: apps, sensores, redes sociais, parceiros
Estrutura	Tabelas com esquema definido	Mistura de estruturados, semiestruturados e não estruturados
Esquema	Definido antes de gravar	Frequentemente definido na leitura, ou ausente
Velocidade	Cargas em lote periódicas	Lote e fluxo contínuo (streaming)
Qualidade	Validada na carga e no modelo	Variável; muitas vezes avaliada depois
Armazenamento	Banco relacional / data warehouse	Data lake, lakehouse, armazenamento de objetos
Risco típico de governança	Silos e definições conflitantes	"Pântano" de dados, dados pessoais ocultos e falta de rastreabilidade

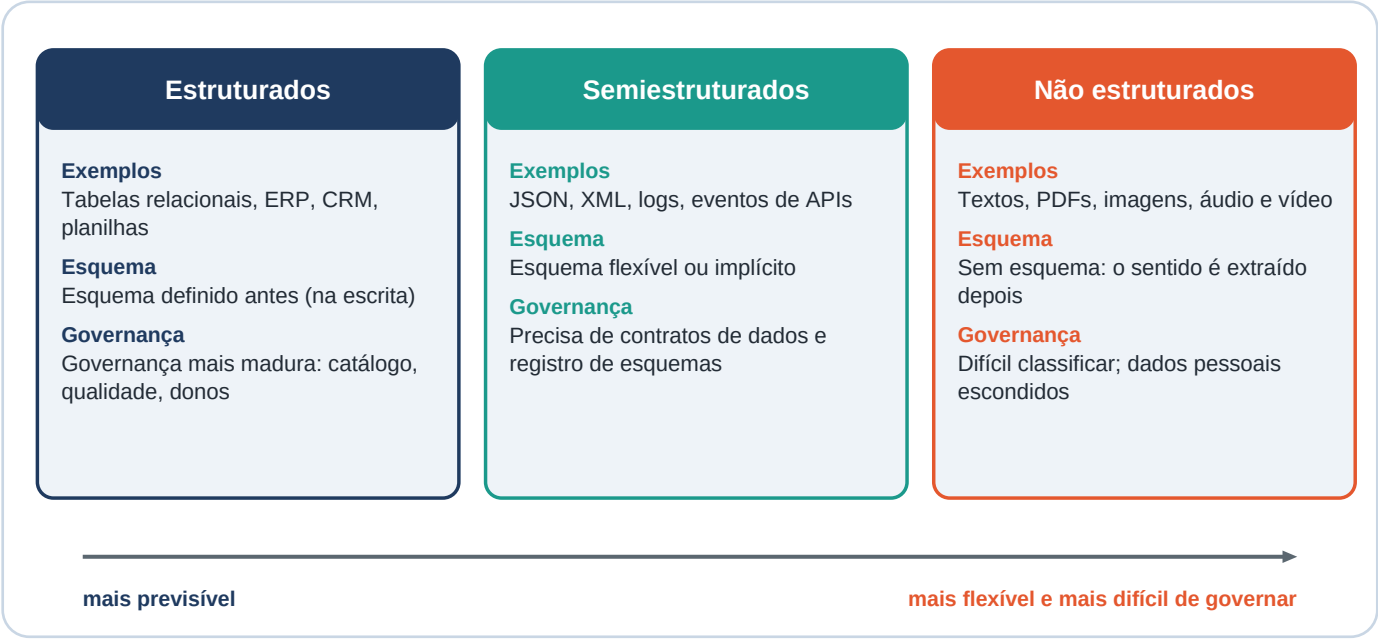


Figura 8 — Do estruturado ao não estruturado: quanto mais flexível o dado, mais a governança depende de metadados e automação.

Na prática, as duas realidades convivem. A maior parte das decisões financeiras e regulatórias continua baseada em dados tradicionais, enquanto análises avançadas e IA consomem também os dados de Big Data. Por isso, a governança precisa funcionar nos dois, com intensidade proporcional ao risco.

Principais desafios de governança em Big Data

- **Catalogar o que não tem esquema.** Sem descrição, dono e classificação, um data lake vira um "data swamp", cheio de dados que ninguém sabe se pode usar.
- **Qualidade em escala.** Não é viável corrigir tudo na mão; é preciso definir o nível de qualidade adequado ao uso e automatizar verificações.
- **Linhagem em fluxos.** Eventos em streaming e transformações em várias etapas tornam difícil rastrear a origem de um valor.
- **Dados pessoais escondidos.** Logs, textos livres, anexos e campos de observações costumam conter CPF, e-mails e outros dados sem que ninguém perceba.
- **Origem e propriedade.** Dados de terceiros e de redes sociais trazem dúvidas sobre direitos de uso e base legal.
- **Segurança e acesso.** Muitos usuários e ferramentas acessando o mesmo repositório exigem controle de acesso detalhado.
- **Custo e retenção.** Armazenar "por via das dúvidas" é barato no início, mas cria custo e risco acumulados.

Onde a governança atua na arquitetura

Uma arquitetura moderna típica envolve fontes, ingestão, zonas de armazenamento e consumo. A governança não é uma etapa nessa linha; ela atravessa todas, por meio de catálogo, linhagem, qualidade, classificação, controle de acesso e retenção.

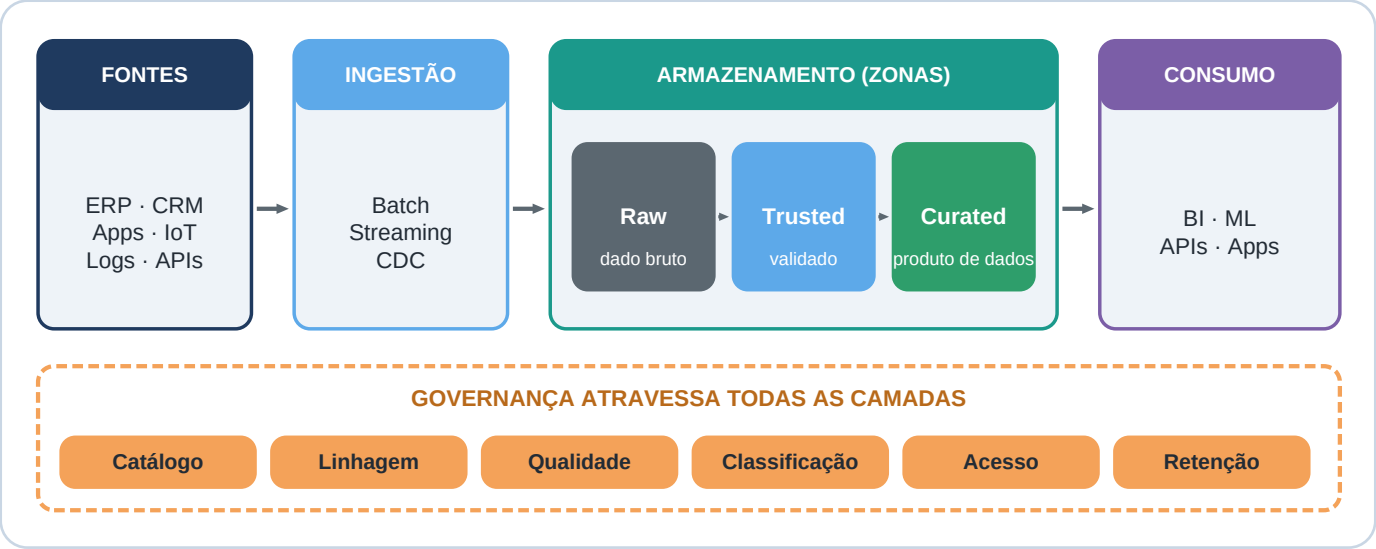


Figura 9 — Governança como camada transversal. As zonas (raw, trusted, curated) correspondem a níveis crescentes de confiança.

Data warehouse, data lake, lakehouse e data mesh

Abordagem	Ideia central	Implicação para governança
Data warehouse	Dados tratados e modelados para análise, com esquema definido	Governança mais direta: modelo claro, donos conhecidos
Data lake	Repositório de dados brutos em formatos variados	Exige catálogo e classificação para não virar pântano
Lakehouse	Combina flexibilidade do lake com gestão e transações do warehouse	Permite controles unificados (acesso, linhagem, qualidade)
Data mesh	Domínios assumem seus dados como produtos, com plataforma comum	Governança federada e computacional: regras comuns aplicadas por automação

O **data mesh**, proposto por Zhamak Dehghani, se apoia em quatro princípios: propriedade por domínio, dados como produto, plataforma de autosserviço e governança federada e computacional. É uma resposta organizacional ao gargalo da centralização, e coloca a governança no centro: sem padrões comuns, os domínios viram silos modernos.

Governança proporcional ao risco

Aplicar o mesmo rigor a todos os dados é caro e atrapalha a agilidade. Uma estratégia comum é **escalar os controles conforme o estágio e a criticidade do dado**: um sandbox exploratório exige pouco; um produto de dados consumido por diretoria e reguladores exige bastante.

Exemplo de governança proporcional ao risco (modelo ilustrativo)

Zona	Classificação	Owner	Qualidade	Acesso	Retenção
Exploratória (sandbox)	opcional	opcional	nenhuma	restrito ao time	curta
Raw	automática	pela fonte	volumetria	mínimo necessário	definida
Trusted	obrigatória	obrigatório	regras básicas	por perfil	definida
Curated (produto)	obrigatória	obrigatório	SLA e monitorada	por perfil + auditoria	política formal

Quanto mais escura a linha, mais controles e mais confiança para o consumo.

Figura 10 — Exemplo de intensidade de controles por zona. É um modelo ilustrativo; cada empresa calibra com base em risco, regulação e uso.

Boas práticas para governar em escala

- **Classificar na ingestão:** aplicar tags de sensibilidade assim que o dado entra, e propagá-las pela linhagem.
- **Automatizar metadados:** coletar esquemas, estatísticas e uso direto dos sistemas, em vez de depender de preenchimento manual.
- **Contratos de dados:** acordos explícitos entre produtor e consumidor sobre esquema, qualidade e frescor.
- **Políticas como código:** regras de acesso, retenção e qualidade verificadas no pipeline.
- **Minimização e retenção:** guardar só o necessário, pelo tempo necessário.
- **Observabilidade de dados:** monitorar frescor, volume, esquema e distribuição para detectar problemas cedo.
- **Rastreabilidade para IA:** registrar quais dados treinaram cada modelo, com versão e origem.

> **Resumo para o seu perfil:** Big Data não pede "menos governança", e sim *governança mais automatizada e mais proporcional*. É exatamente o espaço onde a engenharia de dados tem mais a contribuir.

4

Metadados

O que são metadados

Metadados são **dados que descrevem outros dados**. Uma analogia útil: o rótulo de um produto no supermercado ou a ficha de um livro na biblioteca. Sem o rótulo, você tem o item, mas não sabe o que contém, de onde veio, se está no prazo e se pode ser consumido. Em um ambiente de dados, é o metadado que permite **encontrar, entender, confiar e usar** um dataset corretamente.

Tipos de metadados

Tipo	O que descreve	Exemplos	Quem costuma gerar
Técnico	Estrutura e armazenamento	Esquema, tipos, chaves, formato, partições	Engenharia, automático
De negócio	Significado e regras	Definição, termo do glossário, regra de cálculo, owner	Stewards e negócio
Operacional	Execução e comportamento	Horário de carga, volume, falhas, frescor, consumo	Plataforma e pipelines
De governança	Controle e conformidade	Sensibilidade, base legal, retenção, políticas aplicáveis	Governança, DPO
Social / de uso	Experiência dos usuários	Avaliações, comentários, dashboards que usam o dado	Usuários e catálogo

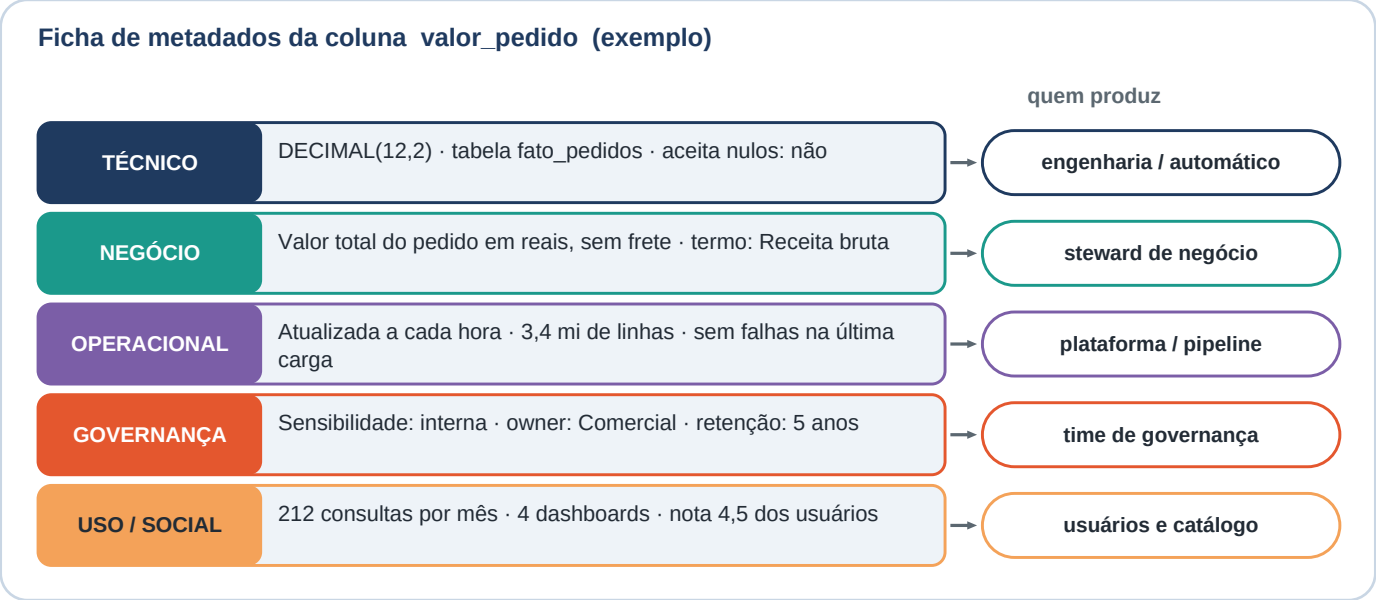


Figura 11 — A mesma coluna descrita por cinco tipos de metadados, cada um com um produtor diferente.

Existem também padrões para organizar e trocar metadados, como o **Dublin Core** (descrição de recursos), o **ISO/IEC 11179** (registro de metadados) e o **DCAT** (descrição de catálogos de dados). Em organizações, o mais comum é adotar um modelo próprio, inspirado nesses padrões.

Metadado passivo e ativo

Em muitas empresas, os metadados ficam **passivos**: documentação que alguém consulta quando lembra. O movimento atual é torná-los **ativos**, ou seja, usá-los para disparar ações automáticas: bloquear acesso a uma coluna classificada como sensível, alertar consumidores quando um esquema muda, ou impedir a publicação de um dataset sem owner.

Glossário, dicionário e catálogo

São termos frequentemente usados de forma intercambiável, mas cumprem papéis diferentes:



Figura 12 — Glossário (negócio), dicionário (técnico) e catálogo (inventário que une os dois e mostra uso). O valor está nas ligações entre eles.

Metadados e linhagem

A linhagem (o caminho do dado da origem ao consumo) é, ela própria, um tipo de metadado muito valioso. Ela tem um capítulo próprio logo a seguir, com níveis de granularidade, métodos de captura, modelo do grafo e propagação de classificação.

Como gerir metadados: um fluxo em cinco passos

- **Coletar:** conectores extraem metadados técnicos e operacionais automaticamente dos sistemas.
- **Enriquecer:** stewards adicionam descrições, termos do glossário, owner e classificação; regras e inteligência podem sugerir classificações.
- **Validar e aprovar:** definições críticas passam por aprovação do owner.
- **Publicar:** o catálogo expõe busca, linhagem e fichas de ativos para os usuários.
- **Usar e retroalimentar:** consumo e feedback dos usuários melhoram os metadados e disparam controles automáticos.

Quanto à arquitetura, os repositórios podem ser **centralizados** (um catálogo único), **distribuídos** (cada sistema mantém o seu) ou **híbridos**, em que há um catálogo central alimentado pelos demais. A abordagem híbrida é a mais comum em ambientes com muitas ferramentas.

Medindo a saúde dos metadados

Metadados também são um produto e precisam de indicadores. Sugestões que podem inspirar seu dashboard:

Indicador	Como calcular (exemplo)	O que mostra
Cobertura de descrição	colunas críticas com descrição / total de colunas críticas	Documentação disponível
Vínculo com glossário	colunas críticas ligadas a um termo / total de colunas críticas	Ponte entre negócio e técnica
Cobertura de owner	datasets com owner / total de datasets	Responsabilização
Cobertura de classificação	colunas classificadas / total de colunas	Base para privacidade e acesso
Cobertura de linhagem	datasets críticos com linhagem de ponta a ponta / total de críticos	Rastreabilidade

Indicador	Como calcular (exemplo)	O que mostra
Frescor dos metadados	ativos com metadado atualizado nos últimos N dias / total	Se a documentação acompanha o dado
Adoção do catálogo	usuários ativos e buscas por mês	Se as pessoas realmente usam

Armadilhas comuns

- **Catálogo cemitério:** carregado uma vez e nunca mais atualizado.
- **Dependência de preenchimento manual** sem automação nem responsáveis.
- **Glossário sem dono** e sem ligação com as colunas reais.
- **Foco em cobertura de cadastro** em vez de utilidade para quem consome.
- **Ferramenta antes do processo:** comprar um catálogo sem definir quem cura e aprova.

> **Conexão com o seu trabalho:** como você já domina classificação, linhagem, ownership e ontologia, o desafio dos metadados é *operacional*: manter tudo vivo, ligado e medido. Os indicadores acima podem entrar direto no seu dashboard em Power BI.

5 Linhagem de dados

O que é e por que importa

Linhagem de dados (data lineage) é o registro da trajetória de um dado: **de onde ele veio**, **por quais transformações passou** e **para onde vai**. É um mapa de dependências entre sistemas, tabelas, colunas, rotinas e relatórios. Na prática, a linhagem responde a perguntas que, sem ela, exigem horas de investigação manual e conversa com várias equipes:

- Se eu mudar o tipo desta coluna, o que vai quebrar?
- Por que o número deste dashboard está diferente do relatório financeiro?
- Quais relatórios usam dados pessoais vindos do CRM?
- Posso desligar este sistema legado sem afetar ninguém?

Dois termos aparecem com frequência. **Linhagem a montante** (upstream, ou backward) olha para trás, em direção às origens. **Linhagem a jusante** (downstream, ou forward) olha para frente, em direção aos consumidores. A primeira ajuda na causa raiz; a segunda, na análise de impacto.

Níveis de granularidade

A linhagem pode ser registrada em níveis de detalhe diferentes. Quanto mais fino o nível, mais útil para auditoria e investigação, mas maior o custo de capturar e manter.

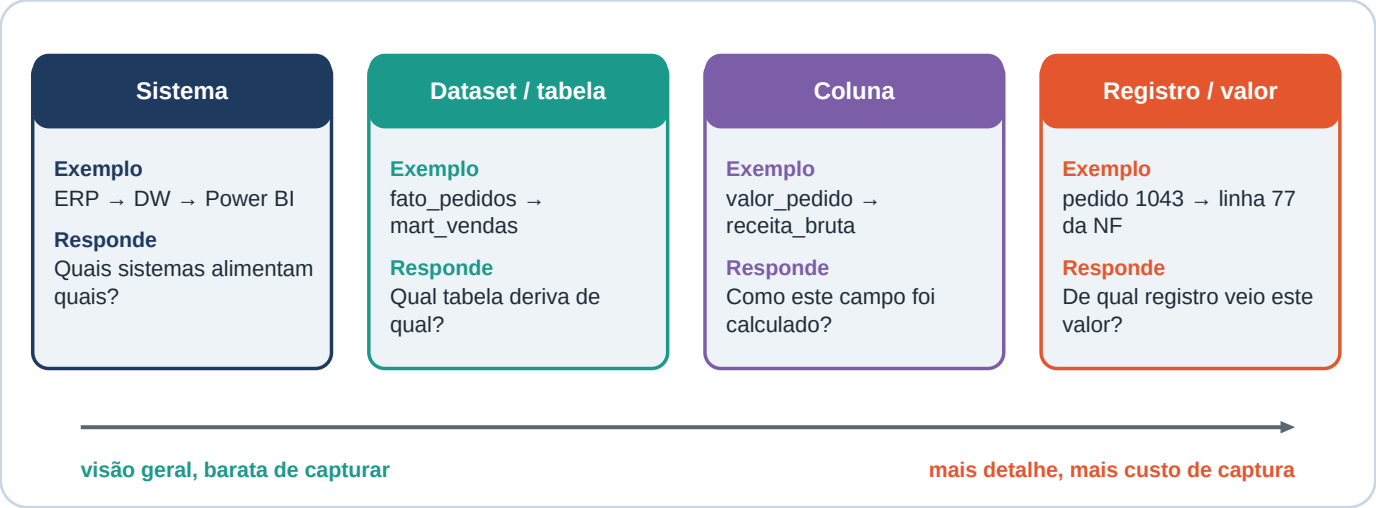


Figura 13 — Quatro níveis de granularidade. A maior parte dos programas começa em dataset e coluna para os dados críticos.

Tipos de linhagem

Tipo	O que mostra	Uso principal	Quem se interessa
Técnica	Tabelas, colunas, jobs e consultas que movem e transformam dados	Impacto de mudanças, causa raiz, otimização	Engenharia, plataforma
De negócio	Processos, sistemas e termos de negócio, em linguagem do negócio	Entender origem de indicadores, apoiar auditoria	Stewards, owners, auditoria
Operacional (de execução)	O que de fato rodou: horário, versão, volume, sucesso ou falha	Reconstruir o que aconteceu em uma execução	Operação, suporte
Projetada x observada	Projetada: derivada do código (design-time). Observada: registrada na execução (run-time)	Comparar o que foi desenhado com o que ocorreu	Engenharia, governança

Casos de uso

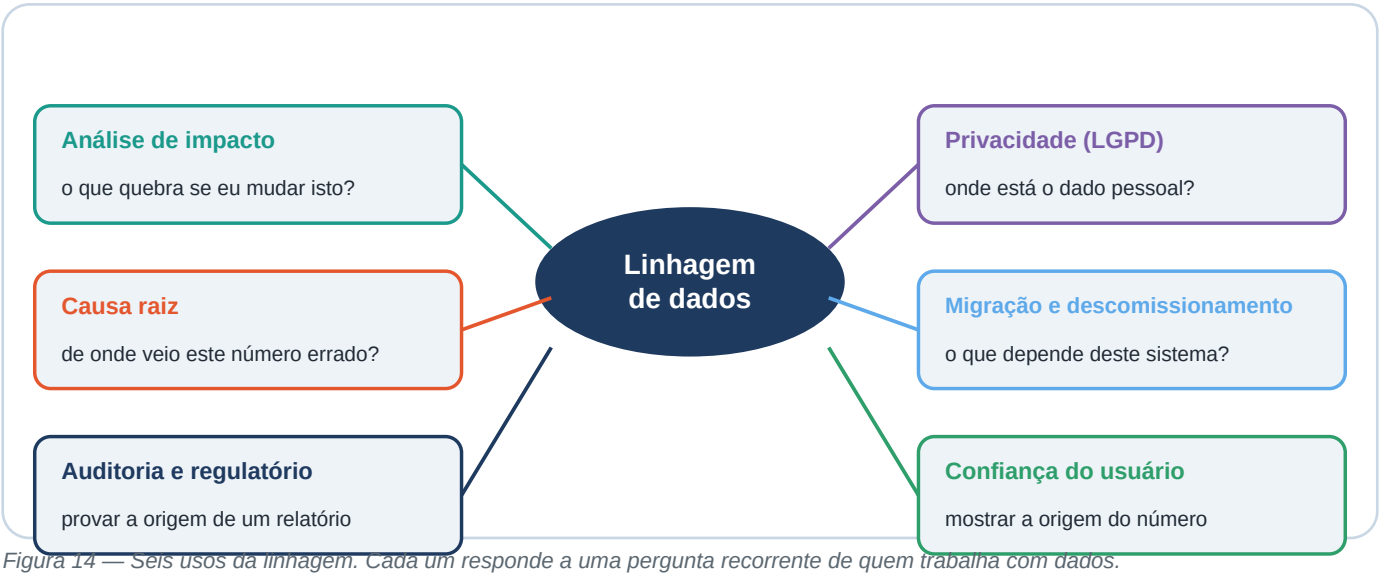


Figura 14 — Seis usos da linhagem. Cada um responde a uma pergunta recorrente de quem trabalha com dados.

- **Análise de impacto:** antes de alterar um esquema, listar todos os consumidores a jusante e avisá-los.
- **Causa raiz:** ao achar um número suspeito, subir o grafo até a origem em vez de investigar sistema por sistema.
- **Auditoria e regulação:** demonstrar de onde vieram os números de um relatório regulatório. Regras de agregação de dados de risco, como as associadas ao BCBS 239, enfatizam rastreabilidade.
- **Privacidade:** localizar onde um dado pessoal aparece, para atender pedidos de titulares e aplicar mascaramento.
- **Migração e descomissionamento:** saber o que depende de um sistema antes de desligá-lo.
- **Custo e limpeza:** encontrar tabelas que ninguém consome e podem ser arquivadas.

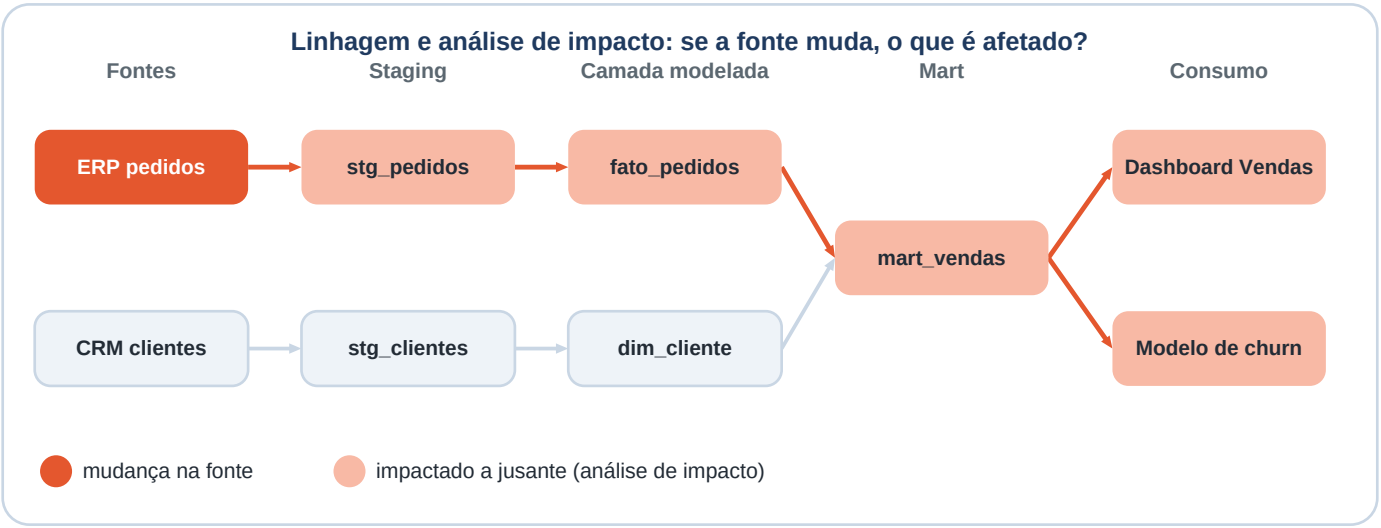


Figura 15 — Grafo de linhagem com análise de impacto. Em vermelho, o que seria afetado por uma mudança no sistema de origem.

Como a linhagem é capturada

Não existe um método único. As organizações combinam várias fontes de sinal, e cada uma tem pontos fortes e fracos:

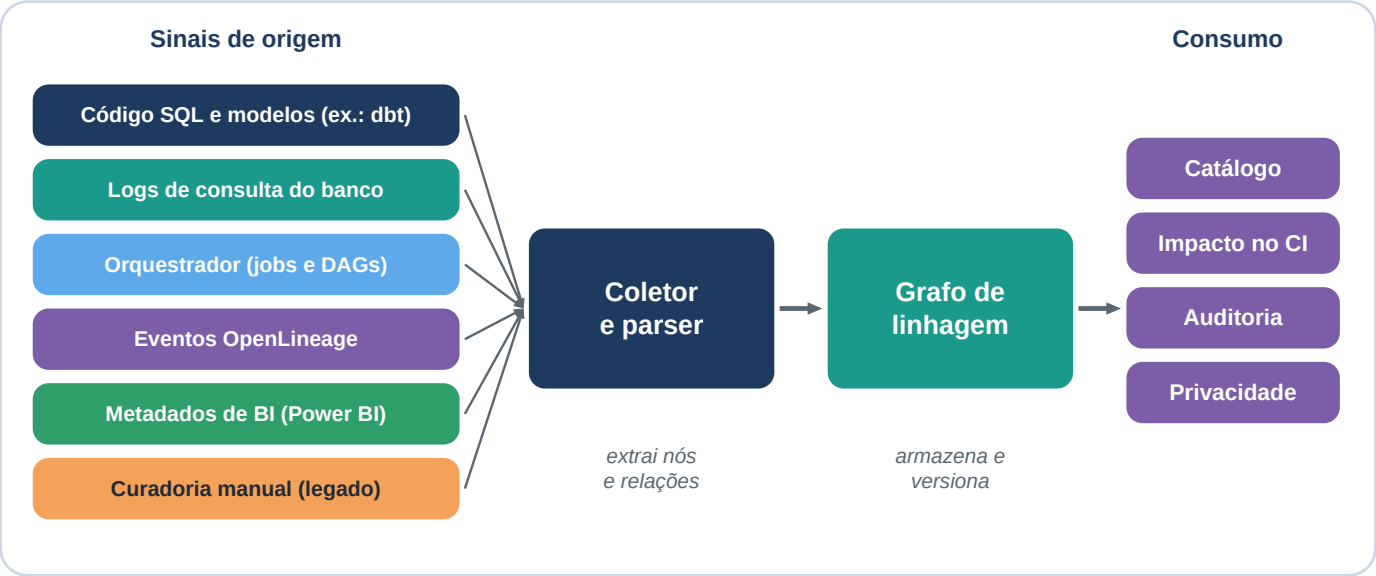


Figura 16 — Do sinal ao consumo: coletores transformam sinais de várias origens em um grafo que alimenta catálogo, CI, auditoria e privacidade.

Método	Como funciona	Pontos fortes	Limitações
Análise de código (parsing)	Lê SQL, modelos e scripts e extrai tabelas e colunas envolvidas	Cobre a lógica antes de rodar; granular em coluna	SQL dinâmico, UDFs e código opaco escapam
Logs de consulta	Usa histórico de queries executadas no banco ou no warehouse	Mostra o que de fato foi executado	Depende de retenção de logs e de acesso a eles
Integração com orquestradores	Lê artefatos de pipelines (ex.: manifest do dbt, DAGs)	Fácil para pipelines padronizados	Cobre só o que passa pela ferramenta
Eventos de linhagem (OpenLineage)	Jobs emitem eventos padronizados de entrada, saída e execução	Padrão aberto, tempo real, multiferramenta	Exige instrumentar ou usar integrações
Metadados de BI	Extrai relações entre fontes, modelos semânticos e relatórios (ex.: API de varredura do Power BI)	Fecha a ponta final, no consumo	Granularidade e disponibilidade variam por licença
Curadoria manual	Pessoas registram dependências que as máquinas não enxergam	Cobre legados e planilhas	Cara, sujeita a erro e desatualização
Inferência	Deduz relações por nomes ou valores semelhantes	Útil quando não há outro sinal	Probabilística; exige validação

Observação sobre Power BI: o serviço oferece uma visão de linhagem entre fontes, modelos semânticos, relatórios e dashboards. Para extrair isso em escala e levar ao catálogo, costuma-se usar a API de varredura de metadados (scanner). Confirme o que está habilitado no seu tenant e na sua licença.

O modelo do grafo

Por baixo, a linhagem é um **grafo**: nós (datasets, colunas, jobs, relatórios) ligados por relações (lê, escreve, deriva de). O padrão OpenLineage, por exemplo, descreve três entidades centrais: *job* (a rotina), *run* (uma execução dela) e *dataset* (entrada ou saída), com *facets* para anexar detalhes como esquema, código ou resultado de qualidade.

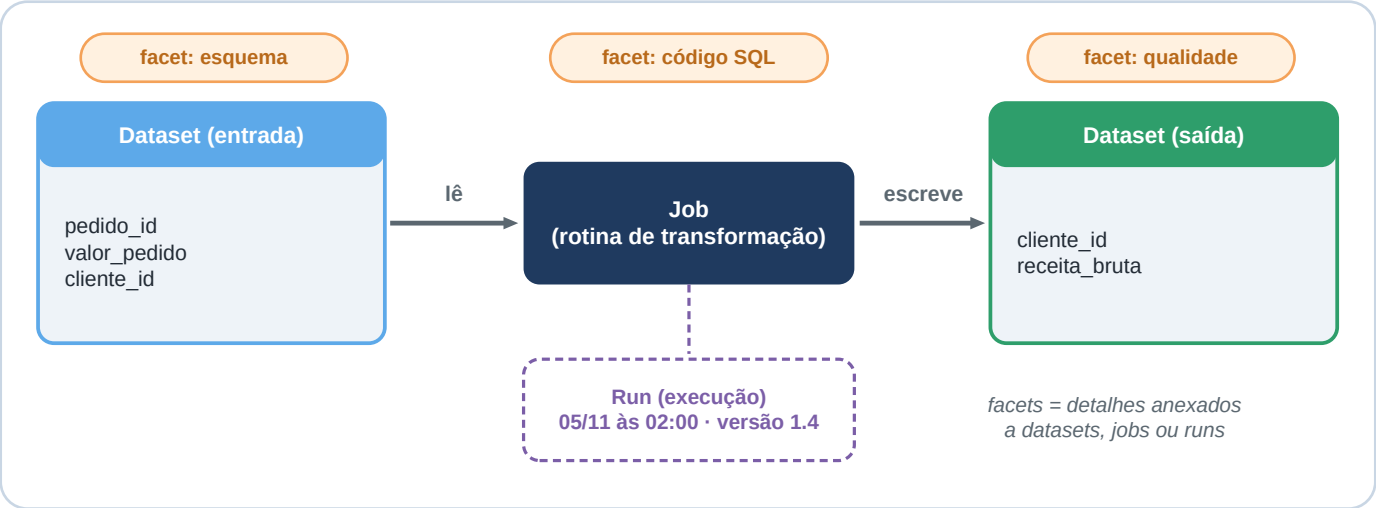


Figura 17 — Entidades do grafo. Separar job (definição) de run (execução) permite reconstruir o histórico.

Linhagem e privacidade: propagando classificação

Uma das aplicações mais valiosas para quem já classifica dados é a **propagação de classificação**. Se a coluna *cpf* do CRM é marcada como dado pessoal, todas as colunas derivadas dela herdam a marcação, a menos que haja uma transformação que a altere (por exemplo, tokenização). Assim, a classificação não precisa ser refeita em cada camada, e o time de privacidade enxerga todos os lugares onde o dado se espalhou.

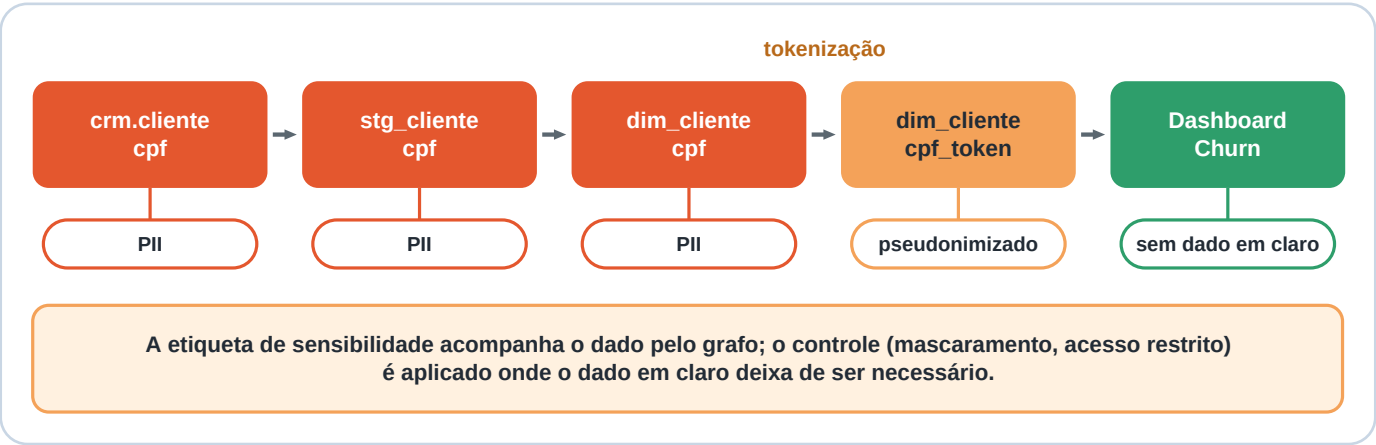


Figura 18 — A etiqueta acompanha o dado. A coluna tokenizada muda de categoria, e o dashboard que só usa o token deixa de expor dado em claro.

Desafios comuns

- **Código opaco:** funções definidas pelo usuário, scripts Python e SQL dinâmico dificultam a extração automática de colunas.
- **Lacunas entre sistemas:** planilhas, extrações manuais e integrações com parceiros costumam ficar fora do grafo.
- **Custo da granularidade de coluna:** o grafo cresce muito e exige armazenamento e consulta eficientes.
- **Tabelas temporárias e ruído:** artefatos intermediários poluem o grafo se não forem tratados.
- **Histórico:** linhagem de hoje não explica um relatório de seis meses atrás se o grafo não é versionado.
- **Streaming:** fluxos contínuos e transformações em janelas exigem modelos próprios de captura.
- **Confiança no próprio grafo:** se a linhagem não é validada, as pessoas deixam de usá-la.

Boas práticas e maturidade

- Comece pelos **dados críticos** (aqueles que alimentam relatórios regulatórios, indicadores executivos e modelos importantes) e expanda.
- Combine **captura automática** com **curadoria manual** para as lacunas, registrando quem validou e quando.

- Valide por **amostragem**: escolha caminhos e confira se o grafo reflete a realidade.
- Traga a linhagem para o **fluxo de mudanças**: análise de impacto automática no pull request ou no pedido de mudança.
- Conecte-a ao **catálogo** para que usuários vejam a origem do dado onde já navegam.
- Mantenha o grafo **versionado** e com política de retenção.

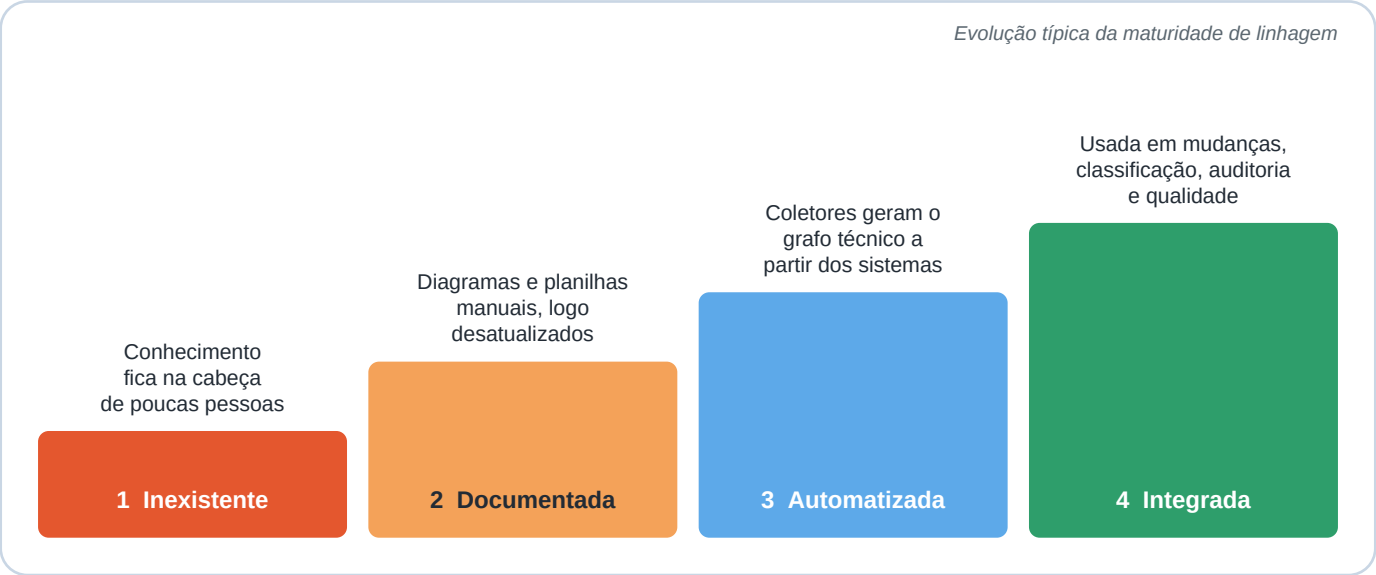


Figura 19 — Escada de maturidade da linhagem. O salto de valor está no nível 4, quando ela passa a ser usada nas decisões do dia a dia.

Indicadores de linhagem para o dashboard

Indicador	Como calcular (exemplo)	O que mostra
Cobertura ponta a ponta de dados críticos	ativos críticos com linhagem da origem ao consumo / total de críticos	Rastreabilidade onde mais importa
Cobertura automática	jobs ou pipelines com linhagem coletada automaticamente / total de pipelines	Esforço manual restante
Frescor da linhagem	ativos cuja linhagem foi atualizada nos últimos N dias / total	Se o grafo acompanha as mudanças
Precisão validada	caminhos conferidos corretos / caminhos conferidos (amostra)	Confiança no grafo
Mudanças com análise de impacto	mudanças que passaram por análise de impacto prévia / total de mudanças	Uso efetivo no processo
Tempo de análise de impacto	tempo médio para listar consumidores afetados	Ganho de produtividade

6

Qualidade dos dados

O que é qualidade de dados

Qualidade de dados é o grau em que os dados atendem às necessidades de quem os usa. A ideia central, vinda da gestão da qualidade em geral, é a **adequação ao uso** (fitness for use): o mesmo dado pode ser bom para um relatório mensal e ruim para uma decisão em tempo real. Por isso, não existe qualidade "em absoluto"; existe qualidade *para um propósito*, e definir esse propósito é o primeiro passo.

A literatura propõe vários modelos de dimensões. O mais citado em governança é o das **seis dimensões do DAMA**. A norma **ISO/IEC 25012** detalha um modelo com quinze características, divididas entre inerentes ao dado (como acurácia, completude, consistência, credibilidade e atualidade), dependentes do sistema (como disponibilidade e recuperabilidade) e ambas (como acessibilidade, conformidade, confidencialidade, eficiência, precisão, rastreabilidade e compreensibilidade).

As dimensões na prática

Dimensão	Pergunta	Exemplo de problema	Como medir (exemplo)
Completude	Os dados esperados estão presentes?	E-mail vazio em cadastro	registros preenchidos / total de registros
Unicidade	Cada entidade aparece uma só vez?	Mesmo cliente com dois cadastros	registros distintos / total de registros
Validade	Segue o formato e as regras definidas?	Data de nascimento no futuro	registros válidos / total de registros
Acurácia	Reflete a realidade?	Endereço que não existe mais	registros corretos conferidos / amostra conferida
Consistência	É igual entre sistemas e campos?	Status "ativo" no CRM e "cancelado" no financeiro	registros coerentes / registros comparados
Atualidade	Está atualizado o bastante para o uso?	Estoque de ontem em decisão de hoje	idade do dado ≤ limite acordado

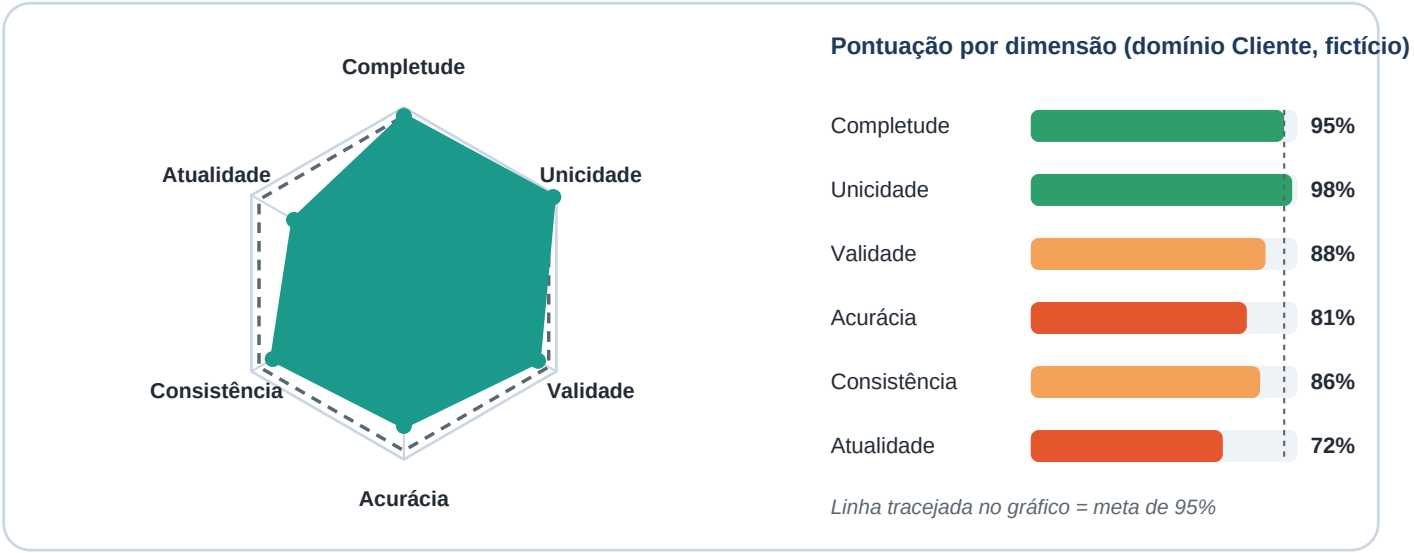


Figura 20 — Radar de qualidade de um domínio fictício. Comparar com a meta mostra rapidamente onde concentrar esforço (aqui, atualidade e acurácia).

O ciclo de gestão da qualidade

Qualidade não é um projeto de limpeza único: é um **processo contínuo**, inspirado em ciclos de melhoria como PDCA e DMAIC. Um desenho comum tem sete passos:

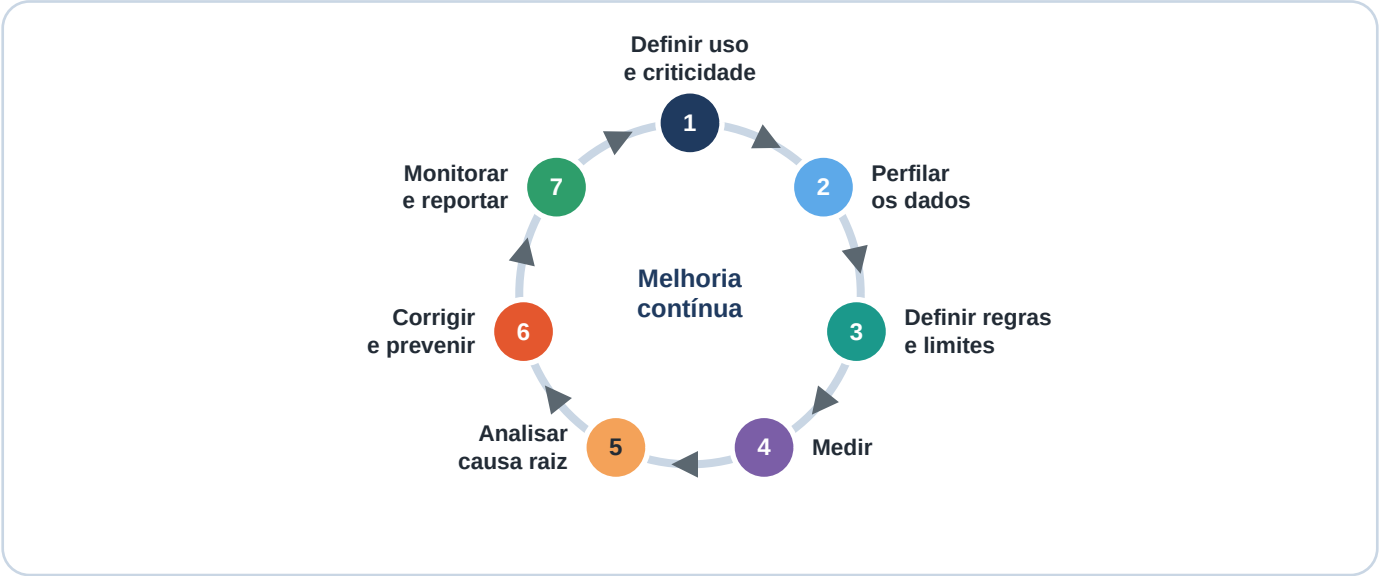


Figura 21 — O ciclo de gestão da qualidade. O passo 1 (uso e criticidade) é o que dá direção aos demais.

- **1. Definir uso e criticidade:** quais dados importam mais e para quê (elementos críticos de dados).
- **2. Perfilar:** entender o estado real dos dados antes de escrever regras.
- **3. Definir regras e limites:** traduzir expectativas em regras mensuráveis, com limites aceitáveis.
- **4. Medir:** executar as regras e calcular scores.
- **5. Analisar causa raiz:** descobrir por que o problema ocorre (a linhagem ajuda muito aqui).
- **6. Corrigir e prevenir:** corrigir os registros e, principalmente, eliminar a causa.
- **7. Monitorar e reportar:** acompanhar a tendência e informar owners e consumidores.

Todos os mecanismos de qualidade, por camada

Os mecanismos de qualidade podem ser agrupados em três famílias: **preventivos** (impedem o erro de entrar), **detectivos** (encontram o erro) e **corretivos** (consertam o erro e evitam repetição). Uma estratégia madura usa os três, em todo o caminho do dado:



Figura 22 — Matriz de mecanismos por etapa e por tipo. Prevenir na origem custa menos do que corrigir no consumo.

Mecanismos preventivos

Mecanismo	Como funciona	Exemplo	Limitação
Validação de entrada	Formulários e APIs recusam dados fora do padrão	Máscara de CPF, lista de estados, data válida	Não protege cargas em lote ou integrações
Restrições do banco	Regras declaradas no esquema	NOT NULL, PRIMARY KEY, UNIQUE, FOREIGN KEY, CHECK	Nem todo sistema de origem usa; difíceis em lakes
Domínios e listas de referência	Valores permitidos mantidos em um só lugar	Tabela de países, de status, de produtos	Exige manutenção e dono
Contratos de dados	Acordo explícito entre produtor e consumidor: esquema, qualidade, frescor	Esquema versionado com regras mínimas	Depende de adoção pelas equipes produtoras
Dados mestres (MDM)	Uma versão confiável de entidades-chave	Cadastro único de cliente	Projeto complexo e organizacional
Testes de código e padronização	Testes automáticos e padrões de nomenclatura e formato no pipeline	Testes unitários de transformação	Cobrem a lógica, não os dados de entrada
Quality gate	Impede publicar o dado se a qualidade estiver abaixo do limite	Pipeline para antes de atualizar o mart	Pode atrasar entregas se mal calibrado

Mecanismos detectivos

Mecanismo	Como funciona	Exemplo
Profiling	Estatísticas descritivas do dado: nulos, cardinalidade, padrões, mín. e máx., distribuição	Descobrir que 6% dos e-mails não têm arroba
Regras de qualidade	Verificações declarativas executadas periodicamente	Valor do pedido maior que zero

Mecanismo	Como funciona	Exemplo
Testes de dados em pipeline	Testes automáticos executados a cada carga	not_null e unique no dbt; expectativas no Great Expectations; regras no Soda, Deequ ou AWS Glue Data Quality
Integridade referencial	Confere se chaves estrangeiras existem nas tabelas de referência	Pedido com cliente inexistente
Reconciliação	Compara contagens e totais entre origem e destino	Soma de valores no ERP versus no DW
Observabilidade de dados	Monitora sinais como frescor, volume, esquema e distribuição	Alerta se a tabela não atualizou hoje
Detecção de anomalias	Estatística ou ML para achar desvios do padrão histórico	Queda inesperada no volume diário
Feedback dos usuários	Canal para consumidores reportarem problemas	Botão "reportar problema" no catálogo

Mecanismos corretivos

- **Padronização e limpeza:** normalizar formatos (datas, telefones, caixa alta/baixa), remover espaços e caracteres inválidos.
- **Enriquecimento:** completar atributos com fontes confiáveis (por exemplo, endereço a partir do CEP).
- **Deduplicação e resolução de entidades:** identificar registros que representam a mesma entidade (com regras exatas ou correspondência aproximada) e consolidar em um registro de ouro.
- **Imputação:** estimar valores faltantes por regra ou estatística, com cuidado e documentando o que foi inferido.
- **Quarentena (dead-letter):** desviar registros inválidos para uma área de revisão, em vez de descartá-los ou deixá-los passar.
- **Correção na fonte x a jusante:** corrigir apenas no destino resolve o sintoma; corrigir na fonte resolve a causa.
- **Reprocessamento (backfill):** reexecutar cargas históricas após a correção, com controle de versão.

Profiling: conhecer antes de regrar

O profiling examina os dados para revelar o que realmente existe, e costuma ser o primeiro passo em qualquer iniciativa. Ele opera em três níveis: **por coluna** (nulos, valores distintos, formato, faixa), **entre colunas** (dependências, como CEP e cidade) e **entre tabelas** (chaves e integridade referencial).

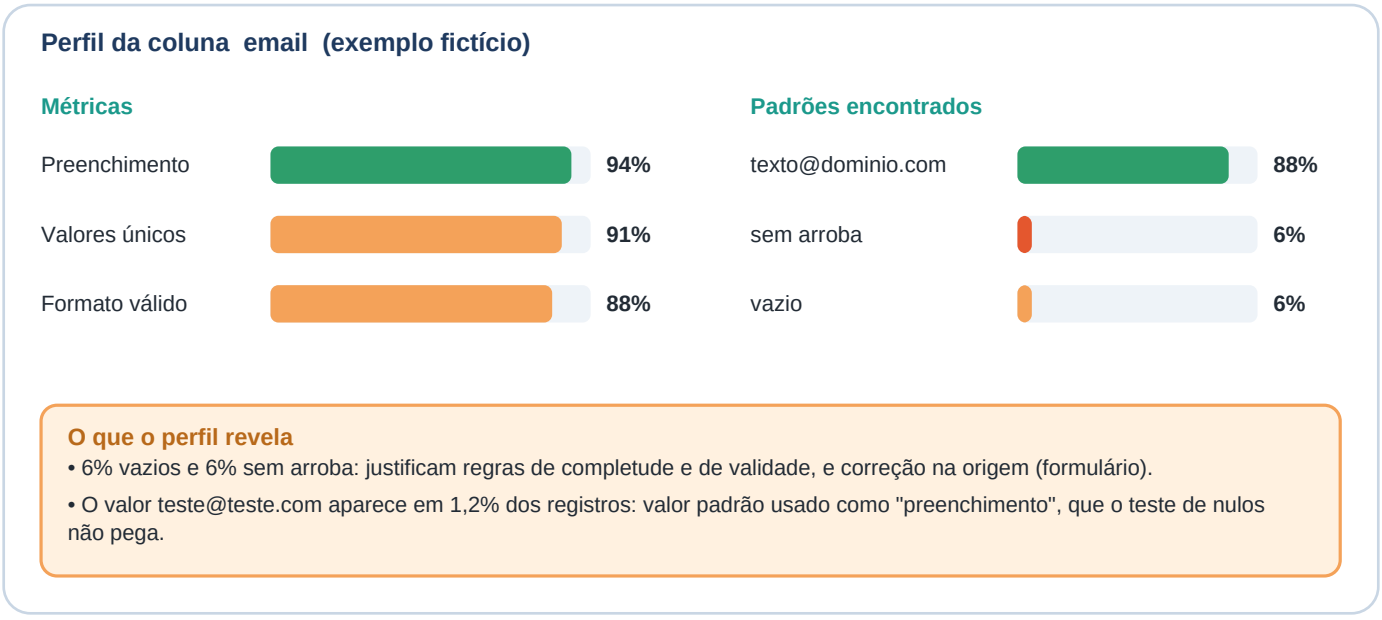


Figura 23 — Exemplo de perfil de coluna. O profiling revela problemas que ninguém pensou em testar, como valores-padrão usados como preenchimento.

Regras de qualidade: exemplos em SQL

As regras devem ser **simples, mensuráveis e ligadas a uma dimensão**. Alguns exemplos genéricos (ajuste a sintaxe ao seu banco):

```
-- Completude: percentual de e-mails preenchidos
SELECT 100.0 * COUNT(email) / COUNT(*) AS pct_preenchido FROM clientes;

-- Unicidade: CPFs duplicados
SELECT cpf, COUNT(*) AS qtd FROM clientes GROUP BY cpf HAVING COUNT(*) > 1;

-- Validade: pedidos com valor invalido
SELECT COUNT(*) AS invalidos FROM pedidos WHERE valor_pedido <= 0 OR valor_pedido IS NULL;

-- Integridade referencial: pedidos sem cliente correspondente
SELECT COUNT(*) AS orfaos FROM pedidos p
LEFT JOIN clientes c ON c.id = p.cliente_id WHERE c.id IS NULL;

-- Atualidade: horas desde a ultima atualizacao
SELECT DATEDIFF(hour, MAX(atualizado_em), CURRENT_TIMESTAMP) AS horas_atraso FROM fato_pedidos;

-- Reconciliacao: diferenca entre origem e destino (execute nos dois e compare)
SELECT SUM(valor_pedido) AS total, COUNT(*) AS linhas FROM pedidos_dia;
```

Para organizar o conjunto de regras, vale classificá-las:

Tipo de regra	Exemplo	Dimensão
Não nulo / obrigatório	cpf não pode ser vazio	Completude
Unicidade	cpf único por cliente ativo	Unicidade
Domínio	status in (ativo, inativo, bloqueado)	Validade
Formato	e-mail com padrão válido	Validade
Intervalo	idade entre 0 e 120	Validade
Referencial	todo pedido tem cliente	Consistência
Entre campos	data de fim ≥ data de início	Consistência
Entre sistemas	saldo do DW = saldo do ledger	Consistência / acurácia
Frescor e volume	carga diária concluída até 6h; variação de volume < 30%	Atualidade
Regra de negócio	desconto máximo de 20% sem aprovação	Acurácia / validade

Medição, limites e score

Cada regra gera um **percentual de conformidade** (registros que passam / registros avaliados). Para reportar, agregam-se as regras em um score por coluna, tabela, domínio ou dado crítico, normalmente com **pesos** que refletem a importância de cada regra:

```
score_dominio = soma(peso_i x score_i) / soma(peso_i)

Exemplo:  completude 95% (peso 3), validade 88% (peso 2), unicidade 99% (peso 3)
score = (95x3 + 88x2 + 99x3) / (3+2+3) = 758 / 8 = 94,75%
```

- **Limites (thresholds)** definem o que é aceitável: por exemplo, verde acima de 95%, amarelo entre 85% e 95%, vermelho abaixo de 85%. Devem ser acordados com o owner e variam com o uso.
- **Amostragem x varredura completa:** amostrar reduz custo, mas pode perder problemas raros; para dados críticos, prefira avaliação completa.
- **Tendência:** o valor absoluto importa, mas a direção importa mais. Um score caindo pede ação mesmo que ainda esteja no verde.

Scorecard de qualidade por domínio (exemplo fictício)

Domínio	Score	Status	Tendência (6 meses)	Regras falhando
Cliente	96%	●	↗	2
Produto	90%	●	→	5
Financeiro	98%	●	↗	1
Pedidos	82%	●	↘	9

● verde: 95% ou mais ● amarelo: 85% a 95% ● vermelho: abaixo de 85%

Figura 24 — Scorecard por domínio, com status, tendência e regras falhando. Pedidos está no vermelho e piorando: prioridade de investigação.

Observabilidade de dados e detecção de anomalias

Regras fixas não cobrem tudo. A **observabilidade de dados** complementa as regras monitorando continuamente sinais de saúde, sem exigir que alguém tenha previsto cada problema. Os sinais mais comuns são:

- **Frescor:** o dado chegou quando devia?
- **Volume:** a quantidade de linhas está dentro do esperado?
- **Esquema:** colunas foram adicionadas, removidas ou mudaram de tipo?
- **Distribuição:** os valores mantêm o comportamento histórico (média, proporção de nulos, categorias)?
- **Linhagem:** um problema em um ponto afeta quais consumidores?

Para detectar desvios, usa-se desde limites simples até modelos estatísticos que aprendem a sazonalidade. O cuidado principal é calibrar para evitar *fadiga de alertas*: se tudo alerta, ninguém reage.

Volume diário de linhas carregadas (exemplo fictício)



Figura 25 — Monitoramento de volume diário com faixa esperada. Dois pontos fora da faixa disparam investigação.

Gestão de incidentes de qualidade

Quando um problema é detectado, é preciso um fluxo claro, para que ele seja tratado e não apenas "apagado":

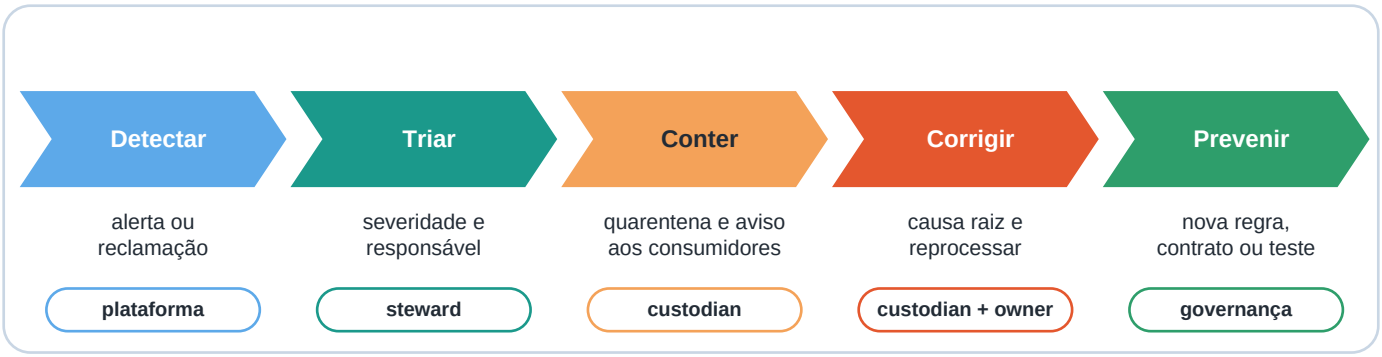


Figura 26 — Fluxo de incidente de qualidade, com o responsável típico de cada etapa.

Severidade	Critério (exemplo)	Resposta esperada
Crítica	Afeta relatório regulatório, decisão financeira ou muitos consumidores	Atuação imediata, comunicação ampla, correção prioritária
Alta	Afeta indicador executivo ou processo importante	Tratamento no mesmo dia útil
Média	Afeta análises específicas, com solução alternativa	Tratamento planejado no ciclo
Baixa	Inconveniência sem impacto relevante	Backlog priorizado

Para a **análise de causa raiz**, técnicas simples ajudam, como os *5 porquês* e o diagrama de causa e efeito (Ishikawa). A pergunta a insistir é: *o que mudaria para que este erro não voltasse a acontecer?* A resposta quase sempre aponta para um mecanismo preventivo (uma validação, um contrato, um teste) ainda ausente.

Papéis, custo e governança da qualidade

Papel	Na qualidade de dados
Data owner	Define o nível de qualidade aceitável e aprova correções e prioridades
Data steward	Define regras e definições, acompanha o score e coordena a resolução de incidentes
Data custodian / engenharia	Implementa regras, testes, quality gates e correções técnicas
Produtor do dado	Responsável por entregar dados conforme o contrato; corrige na origem
Consumidor	Informa o uso e a criticidade; reporta problemas
Time de governança	Padroniza dimensões, limites, métricas e o processo de incidentes

Custo da má qualidade: aparece como retrabalho, decisões equivocadas, perda de confiança, multas e oportunidades perdidas. Uma heurística popular (a "regra 1-10-100") diz que prevenir custa pouco, corrigir depois custa mais e falhar diante do cliente custa muito mais. Não é uma lei exata, mas expressa bem por que prevenir na origem compensa.

Qualidade para IA e analytics

Modelos de aprendizado de máquina trazem preocupações extras: **qualidade dos rótulos**, **representatividade** da amostra, **desvio de dados** (data drift) entre treino e produção e **consistência entre dados de treino e de inferência**. A linhagem registra quais dados treinaram cada modelo, e as regras de qualidade devem rodar também sobre as features.

Armadilhas comuns

- **Regras demais, sem priorização:** centenas de regras sobre dados irrelevantes escondem o que importa.
- **Medir sem agir:** scorecard sem dono nem plano de correção vira decoração.
- **Qualidade só a jusante:** limpar no dashboard enquanto a fonte continua errada.
- **Limites arbitrários:** definidos sem conversar com quem usa o dado.

- **Alertas em excesso:** equipe aprende a ignorá-los.
- **Ignorar o contexto de uso:** exigir o mesmo rigor de todo dado.
- **Tratar qualidade como projeto:** sem rotina, o score decai com o tempo.

Indicadores de qualidade para o dashboard

Indicador	Como calcular (exemplo)	O que mostra
Score de qualidade por domínio	média ponderada dos scores das regras do domínio	Saúde geral e tendência
Regras passando	regras com conformidade ≥ limite / total de regras	Proporção de regras atendidas
Cobertura de regras em dados críticos	colunas críticas com ao menos uma regra ativa / total de colunas críticas	Se o crítico está monitorado
Incidentes abertos por severidade	contagem de incidentes em aberto por classe	Carga de trabalho e risco
Tempo de detecção (MTTD)	tempo médio entre o problema ocorrer e ser detectado	Eficácia da detecção
Tempo de resolução (MTTR)	tempo médio entre a detecção e a correção	Eficiência da resposta
Pipelines com quality gate	pipelines com bloqueio por qualidade / total de pipelines críticos	Prevenção automatizada
Reincidência	incidentes com mesma causa raiz em 90 dias / total	Se a causa está sendo resolvida

Dica para o seu dashboard: prefira indicadores de *resultado* (score, incidentes, tempos de detecção e resolução, reincidência) acompanhados de alguns de *cobertura* (regras em dados críticos). Cobertura sem resultado diz que há regras; resultado sem cobertura pode esconder o que não está sendo medido.

7 Governança, gerência e a ética nos dados

Ética não é a mesma coisa que lei

Cumprir a lei é o ponto de partida. A **ética de dados** trata dos valores e princípios que orientam a coleta, o uso e o compartilhamento de dados, incluindo situações que a lei ainda não previu ou deixa em aberto. Algo pode ser legal e, ainda assim, provocar surpresa, desconfiança ou dano a pessoas.

Por isso muitas organizações perguntam duas coisas antes de um novo uso de dados: "podemos?" (conformidade) e "devemos?" (ética). A segunda protege tanto as pessoas quanto a reputação da empresa.

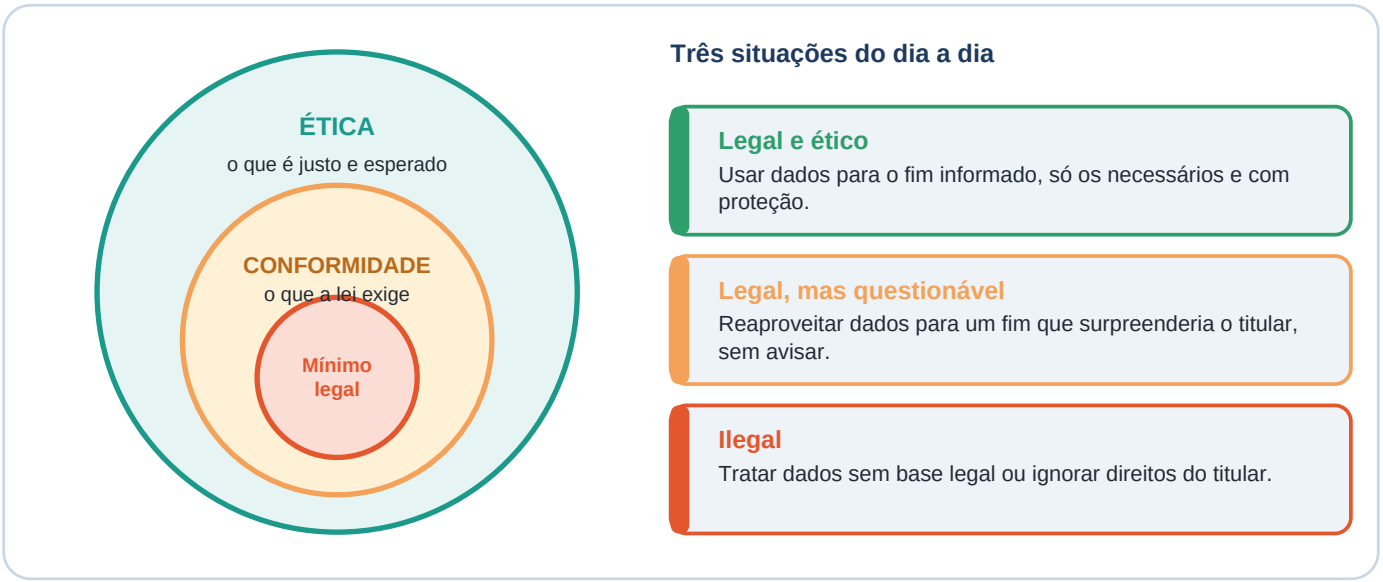


Figura 27 — A conformidade é o mínimo; a ética cobre também o que é justo e esperado pelas pessoas.

Princípios que orientam o uso responsável

Há diferentes listas de princípios (OCDE, empresas, órgãos reguladores). Elas convergem em torno de ideias semelhantes, que na LGPD aparecem no art. 6º como princípios do tratamento de dados pessoais. A tabela relaciona os mais usados:

Princípio	Pergunta prática	Na LGPD (art. 6º)
Finalidade	Para que exatamente usaremos este dado?	Finalidade e adequação
Minimização	Precisamos mesmo de todos esses campos?	Necessidade
Transparência	A pessoa sabe e consegue entender o uso?	Transparência e livre acesso
Autonomia	A pessoa teve escolha real e pode revisar?	Livre acesso; direitos do titular
Justiça	O resultado trata grupos de forma equitativa?	Não discriminação
Segurança	O dado está protegido contra uso indevido?	Segurança e prevenção
Qualidade	O dado é correto e atualizado para esse uso?	Qualidade dos dados
Responsabilização	Conseguimos demonstrar o que fizemos e por quê?	Responsabilização e prestação de contas

Viés e justiça em algoritmos

Modelos e regras automáticas aprendem com dados do passado, e o passado pode conter desigualdades. O viés não nasce só no algoritmo: ele pode entrar em qualquer etapa da cadeia, e as decisões automatizadas podem

alimentá-lo de volta.

- **Coleta:** quem aparece nos dados? Grupos sub-representados tendem a receber resultados piores.
- **Rotulagem:** rótulos criados por pessoas carregam julgamentos subjetivos.
- **Proxies:** variáveis aparentemente neutras (como CEP) podem funcionar como substitutas de renda, raça ou outras características sensíveis.
- **Métricas:** otimizar só a acurácia média pode esconder desempenho ruim em subgrupos.
- **Retroalimentação:** decisões enviesadas geram novos dados que reforçam o padrão.

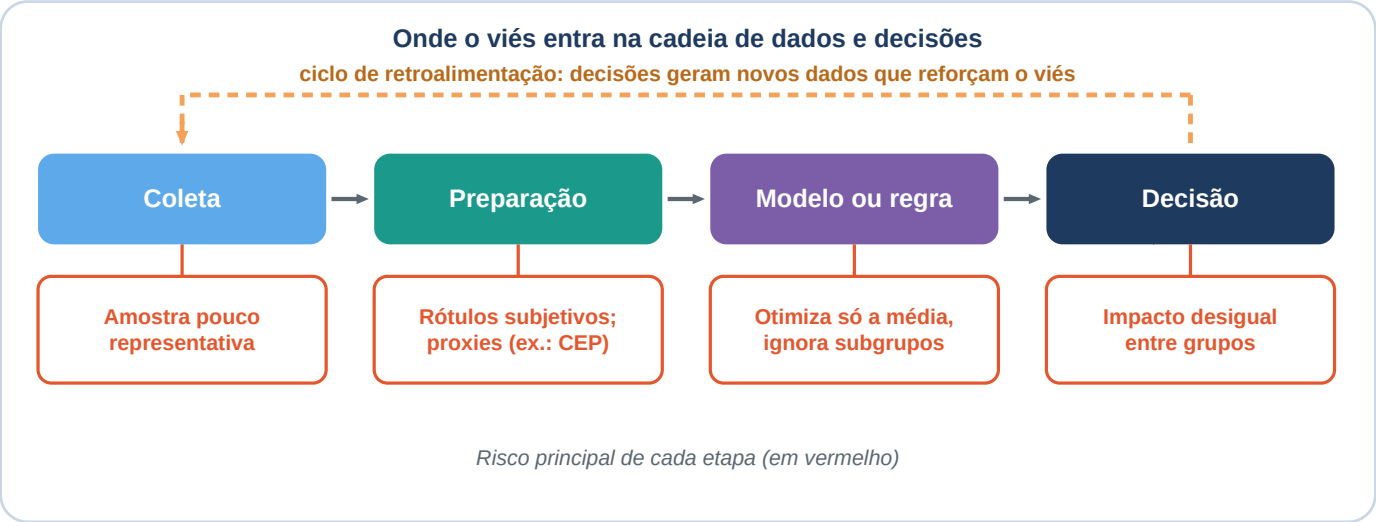


Figura 28 — Pontos de entrada do viés. Mitigar exige olhar para toda a cadeia, não apenas para o modelo.

A LGPD prevê, no art. 20, o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado que afetem os interesses do titular, o que liga o tema diretamente à necessidade de explicabilidade e de registro dessas decisões.

Privacidade, anonimização e reidentificação

Duas ideias frequentemente confundidas: **anonimizar** e **pseudonimizar**. Dados anonimizados, de forma que não seja possível identificar a pessoa por meios razoáveis, deixam de ser dados pessoais. Dados pseudonimizados (por exemplo, com CPF trocado por um código) continuam sendo dados pessoais, pois podem ser reidentificados com informação adicional. Além disso, combinar bases "anonimizadas" pode permitir reidentificar pessoas.

Técnica	O que faz	Observação
Mascaramento	Oculta parte do valor (ex.: ***.456.789-**)	Útil para exibição; não garante anonimato
Tokenização / pseudonimização	Troca o dado por um código reversível com chave separada	Continua sendo dado pessoal
Generalização	Reduz precisão (idade exata vira faixa etária)	Diminui risco de identificação
k-anonimato	Garante que cada combinação de atributos apareça em ao menos k pessoas	Pode falhar contra ataques de inferência
Privacidade diferencial	Adiciona ruído controlado para proteger indivíduos em estatísticas	Equilibra utilidade e proteção

Como institucionalizar a ética

Valores só funcionam quando viram rotina. Algumas práticas comuns:

- **Princípios e código de conduta** aprovados pela alta gestão e conhecidos por quem lida com dados.
- **Comitê ou fórum de ética e privacidade** para casos novos ou de alto impacto, com participação de áreas jurídica, negócios, tecnologia e DPO.

- **Avaliação de impacto** antes de usos sensíveis (perfilamento, IA, dados de saúde, crianças).
- **Privacidade e ética desde a concepção**, ou seja, pensadas no projeto, não depois do lançamento.
- **Treinamento e canal de questionamento** sem retaliação.
- **Registro de decisões**, para demonstrar responsabilização.

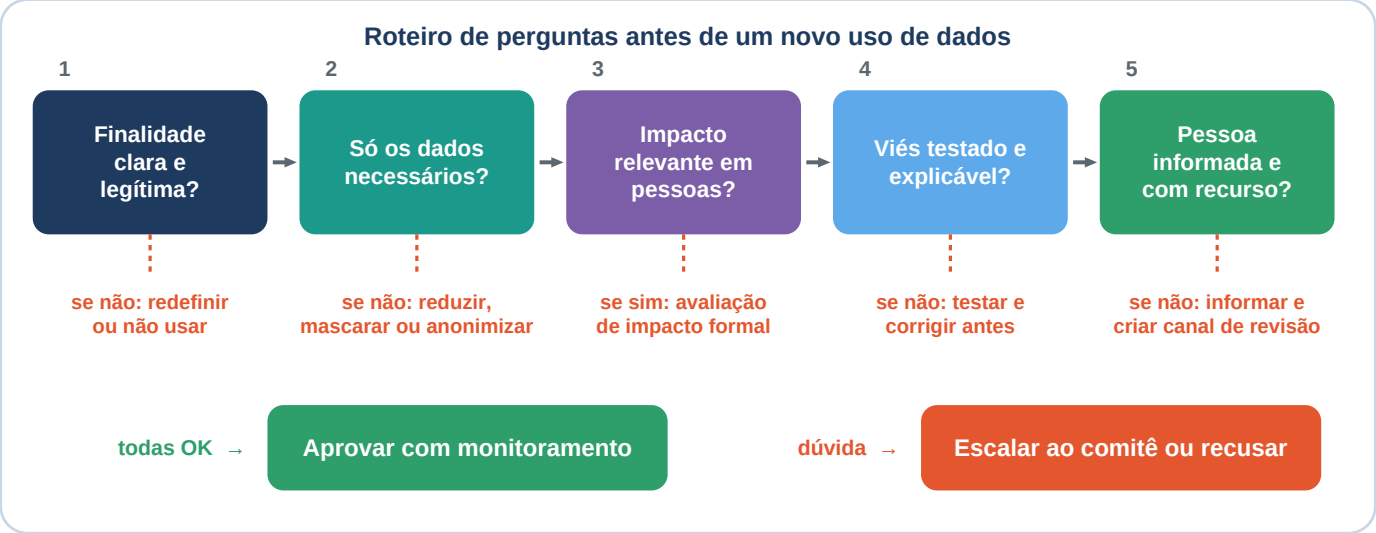


Figura 29 — Roteiro simples de perguntas para novos usos de dados. As respostas negativas disparam ajuste, escalonamento ou recusa.

Casos para reflexão (hipotéticos)

- Um modelo de concessão de crédito usa o CEP como variável. O modelo é preciso, mas penaliza bairros periféricos. Qual deveria ser a decisão?
- Uma empresa quer reutilizar dados de atendimento médico (coletados para cuidado) em campanhas de marketing. Há base legal? E expectativa razoável do titular?
- Uma base é "anonimizada" removendo nome e CPF, mas mantém data de nascimento, CEP e profissão. É realmente anônima?
- Um sistema automatizado nega um pedido e ninguém consegue explicar o motivo. Que direitos e deveres estão envolvidos?

O papel da engenharia de dados

A ética parece abstrata, mas se concretiza em decisões técnicas do dia a dia:

- Aplicar tags de sensibilidade e mascaramento de forma automática.
- Registrar linhagem e origem dos dados usados em modelos.
- Manter trilhas de auditoria de acesso.
- Documentar datasets e modelos (existem práticas conhecidas como *datasheets for datasets* e *model cards*).
- Questionar usos que pareçam fora da finalidade e levá-los ao fórum correto.

Agilidade, dados e governança de dados

Governança e agilidade: aliadas, não rivais

Quando se fala em governança, muita gente imagina comitês, formulários e aprovações. Quando se fala em agilidade, imagina-se autonomia, entregas curtas e mudança constante. Se a governança é desenhada como uma sequência de portões manuais, ela de fato conflita com times que entregam a cada duas semanas, e o resultado é conhecido: os times contornam a governança (os chamados dados "de sombra") ou a governança vira gargalo.

A saída não é escolher um lado, e sim **mudar o desenho da governança**: em vez de portões que paralisam, **guardrails** (trilhos de proteção) que permitem andar rápido com segurança. Isso significa embutir regras no caminho de trabalho, automatizar o que for possível e deixar decisões humanas para o que realmente exige julgamento.

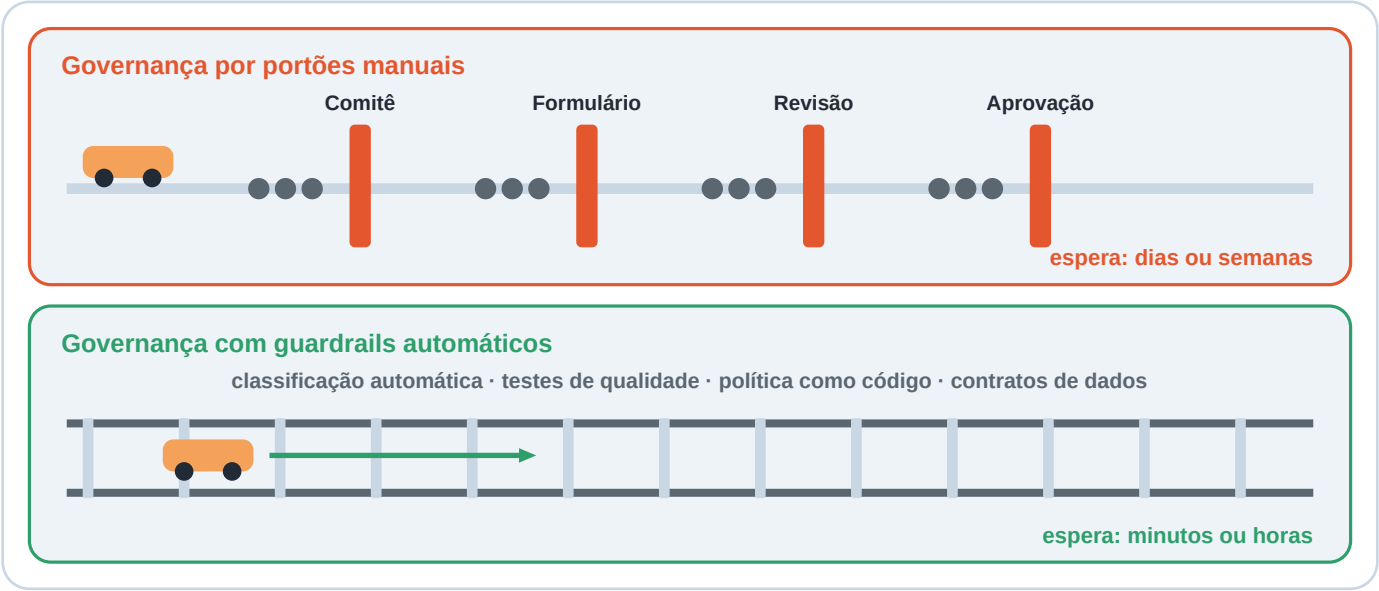


Figura 30 — Portões manuais x guardrails automáticos. O objetivo da governança é o mesmo; muda o mecanismo e o tempo de espera.

Princípios ágeis aplicados à governança de dados

O Manifesto Ágil (2001) propõe valorizar pessoas e interações, software funcionando, colaboração com o cliente e resposta a mudanças. Traduzido para dados, e em diálogo com ideias de DataOps, isso leva a escolhas práticas:

Valor ágil (resumo)	Como aparece na governança de dados
Pessoas e interações acima de processos e ferramentas	Stewards trabalhando junto dos times, em vez de um comitê distante que só recebe pedidos
Software funcionando acima de documentação extensa	Catálogo, linhagem e regras que são geradas e verificadas automaticamente, em vez de documentos longos que ninguém atualiza
Colaboração com o cliente acima de negociação de contratos	O owner participa do refinamento do backlog e valida o que importa; contratos de dados são combinados entre produtor e consumidor
Responder a mudanças acima de seguir um plano	Políticas versionadas e revisadas com frequência; evolução incremental dos padrões conforme o aprendizado

No campo de dados, esse pensamento ganhou técnicas conhecidas, muitas delas popularizadas por Scott Ambler: **modelagem de dados enxuta** (apenas o necessário), **evolução incremental do banco**, **refatoração de bancos de dados** com mudanças pequenas e seguras e **testes de regressão de dados**. A ideia é tratar o esquema como algo vivo, que evolui com testes e automação, e não como um desenho fechado que exige aprovações longas a cada alteração.

Disciplined Agile (DA) e o Disciplined Agile Delivery (DAD)

O **Disciplined Agile** é um toolkit criado por Scott Ambler e Mark Lines, hoje mantido pelo PMI (o instituto o incorporou em 2019). O **DAD**, a parte dedicada à entrega de soluções, é descrito como uma abordagem híbrida, que coloca as pessoas em primeiro lugar e valoriza o aprendizado. Ele não impõe um método único: funciona como um **framework de decisão de processo**, que ajuda cada equipe a escolher e adaptar o seu jeito de trabalhar (o chamado "Choose Your WoW", ou escolha seu modo de trabalho).

- **Princípios:** encantar o cliente, ser excelente, o contexto importa, ser pragmático, escolher é bom, otimizar o fluxo e ter consciência da empresa como um todo.
- **Ciclos de vida:** há opções como ágil (estilo Scrum), lean (estilo Kanban), entrega contínua, exploratório (lean startup) e de programa (equipe de equipes). A equipe escolhe o que serve ao seu contexto.
- **Fases:** Inception (concepção), Construction (construção) e Transition (transição), mais metas contínuas (Ongoing).
- **Metas de processo:** em vez de listar práticas obrigatórias, o DAD apresenta metas (como "melhorar a qualidade") com pontos de decisão e opções para cada uma.
- **Camadas do toolkit:** fundação, Disciplined DevOps, fluxos de valor e a empresa ágil disciplinada. O DAD é uma das áreas ("process blades") do Disciplined DevOps.

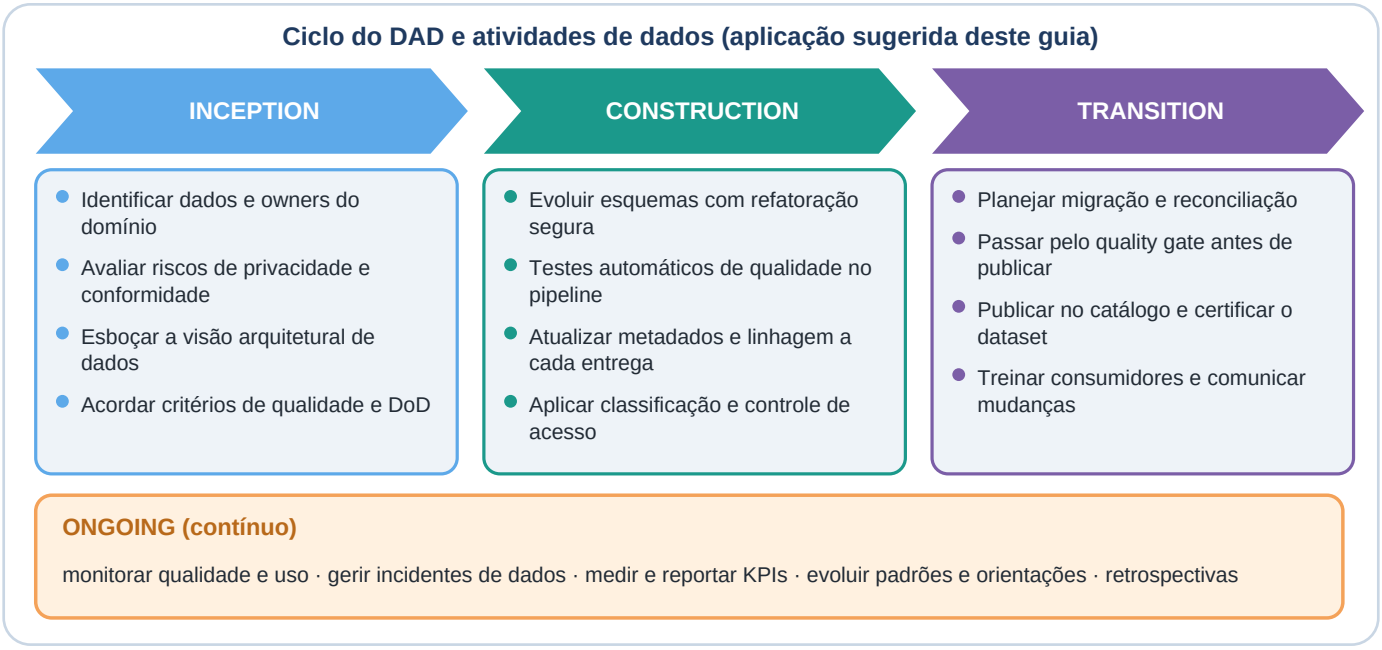


Figura 31 — As três fases do DAD com exemplos de atividades de dados em cada uma. As atividades de dados são uma aplicação sugerida por este guia, não uma lista oficial.

O que o Disciplined Agile diz sobre dados

O toolkit tem uma área específica para **gestão de dados** (process blade "Data Management"). Segundo o material publicado pelo PMI, a orientação é sair de uma gestão de dados lenta e pesada em documentação para uma abordagem colaborativa, enxuta e orientada à qualidade, que **habilita** as equipes em vez de apenas controlá-las. O raciocínio central é que as equipes de entrega fazem a maior parte do trabalho de evoluir as fontes de dados, com orientação e apoio da gestão de dados, e não o contrário (equipes documentando mudanças, aguardando revisões e depois seguindo longas filas de aprovação).

As metas descritas nessa área incluem consolidar dados de várias fontes, fornecer inteligência (por exemplo, BI de autosserviço), melhorar a qualidade dos dados, garantir a segurança, refatorar fontes legadas e **governar os dados**. Para esta última meta, as decisões giram em torno de quatro temas:

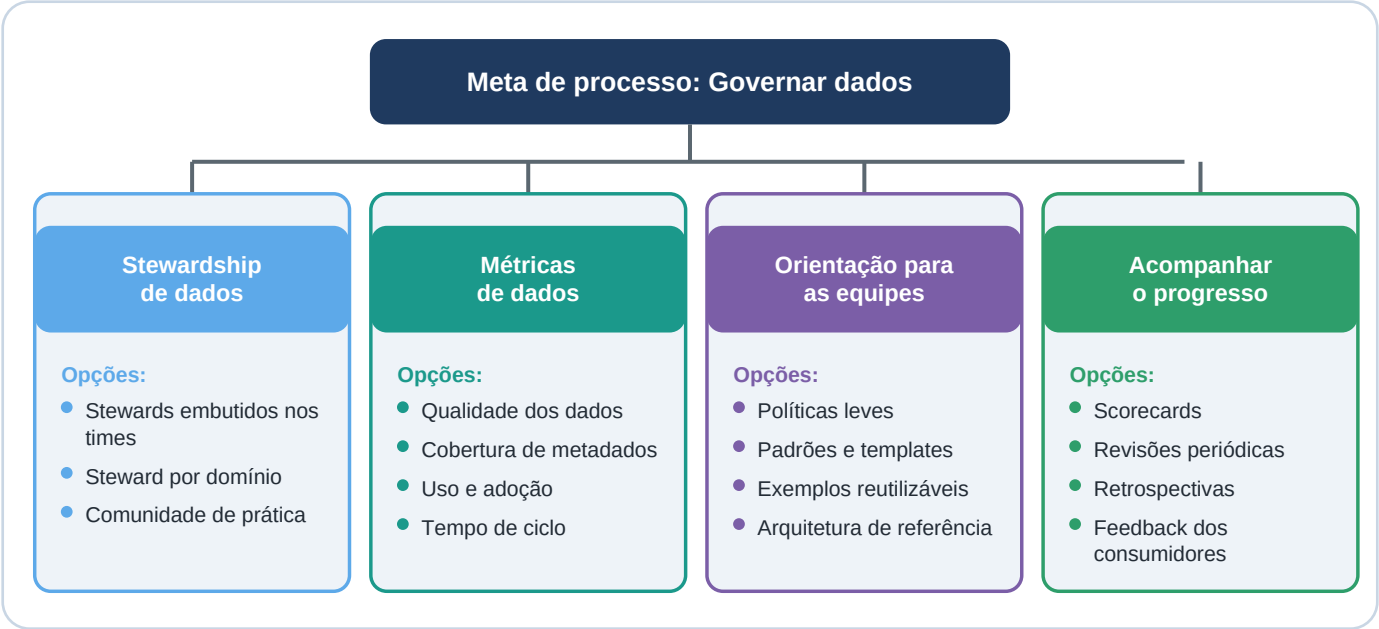


Figura 32 — Pontos de decisão da meta "Governar dados", traduzidos e exemplificados. Consulte o DA Browser do PMI para a versão oficial e atual.

Os papéis do DAD também são úteis para pensar em governança. Entre eles aparecem o *Team Lead*, o *Product Owner*, o *Architecture Owner* e o *Team Member*, além de papéis de apoio como *Specialist* (especialista), *Domain Expert* e *Technical Expert*. Uma tradução natural: o **steward de dados** atua como especialista ou especialista de domínio ligado ao time, e o **Architecture Owner** faz a ponte com a arquitetura de dados da empresa. O **owner** do domínio costuma aparecer como parte interessada (stakeholder) forte, e em alguns arranjos acumula funções com o Product Owner de um produto de dados.

SAFe: governança em escala

O **Scaled Agile Framework (SAFe)**, criado por Dean Leffingwell e mantido pela Scaled Agile, Inc., organiza a agilidade para muitos times trabalhando juntos. A versão 6.0, lançada em março de 2023, foi por anos a referência. Em 23 de junho de 2026, a Scaled Agile anunciou o **AI-Native SAFe**, nova versão que coexiste com o Core SAFe e que, segundo o comunicado, trata governança e ética, especificações e intenção e **gestão de dados curada** como elementos de primeiro plano. Confira o material oficial para saber qual versão sua organização adota.

- **Agile Release Train (ART):** o "trem" que reúne várias equipes (em geral algumas dezenas de pessoas) em torno de uma cadeia de valor, com cadência comum.
- **PI Planning:** evento de planejamento conjunto a cada incremento de programa, normalmente de 8 a 12 semanas.
- **Papéis do ART:** Release Train Engineer (facilita o trem), Product Management, System Architect e Business Owners.
- **Enablers:** itens de backlog que preparam o terreno (arquitetura, infraestrutura, exploração e conformidade), importantes para trabalhos de dados que não são "funcionalidade".
- **Qualidade embutida, DoD e requisitos não funcionais:** a qualidade é responsabilidade do time, e requisitos como privacidade, retenção e qualidade de dados entram no trabalho.
- **Entrega contínua:** exploração, integração, implantação e liberação sob demanda.
- **Lean Portfolio Management (LPM):** reúne investimento estratégico, operações ágeis de portfólio e **governança enxuta** (lean governance), que acompanha gasto, auditoria, conformidade e medição com métricas leves. Os orçamentos e **guardrails** dão autonomia aos times dentro de limites claros.
- **Comunidades de prática:** grupos que compartilham conhecimento entre times, como uma comunidade de data stewards.

Em resumo, a governança do SAFe é **distribuída em camadas**: o portfólio define estratégia, financiamento e limites; o trem coordena e entrega; os times executam com qualidade embutida. Dados entram em todas as

camadas:

Nível	Elementos do SAFe	Pontos de contato da governança de dados
Portfólio	Lean Portfolio Management: estratégia e financiamento, operações ágeis e governança enxuta; épicos e guardrails	Políticas de dados como guardrails; épicos de governança com business case enxuto; riscos e conformidade no radar
Trem de entrega (ART)	Agile Release Train, PI Planning, backlog do ART, enablers, system demo, Inspect & Adapt	Dependências e owners de dados no PI Planning; enablers (catálogo, linhagem, qualidade); KPIs revistos no I&A
Time	Scrum ou Kanban, Definition of Done, qualidade embutida, práticas de DevOps	DoD de dados; testes de qualidade no pipeline; stewards como especialistas ligados ao time
Transversal	Comunidades de prática, arquitetura e padrões compartilhados	Comunidade de data stewards; arquitetura de referência de dados; glossário comum

Figura 33 — Onde a governança de dados se conecta aos níveis do SAFe. A coluna da direita é uma aplicação sugerida por este guia.

No ritmo do trem, os pontos de contato são previsíveis: planejar dependências de dados no início, aplicar a Definition of Done a cada entrega, e revisar os indicadores no encerramento do incremento.

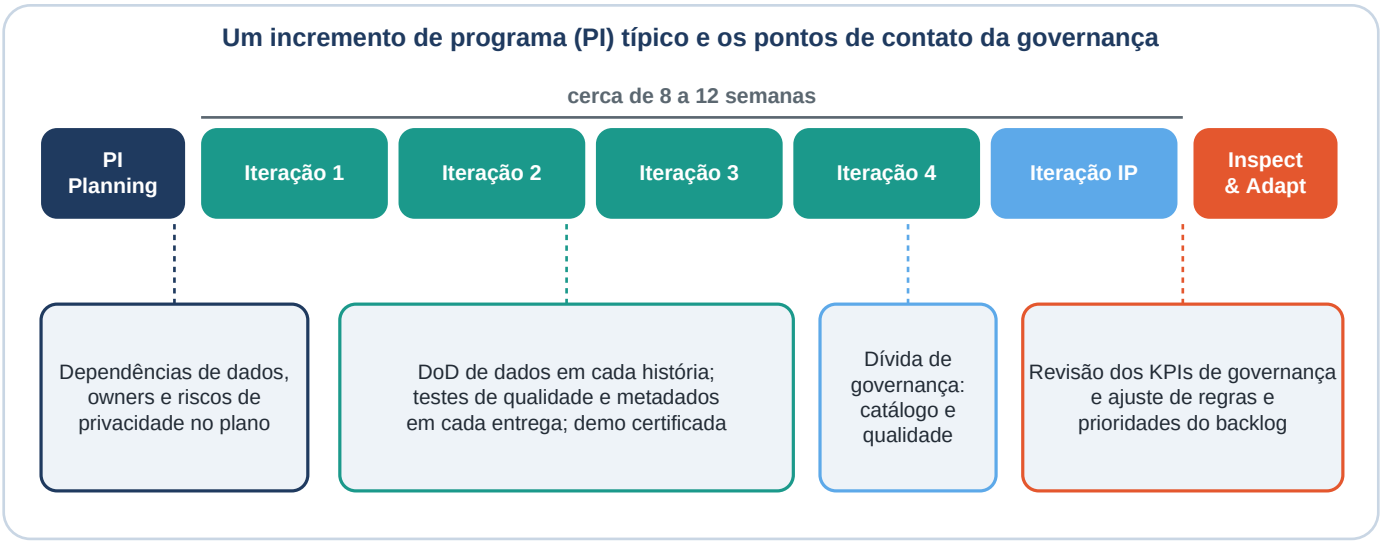


Figura 34 — Calendário de um incremento de programa com os momentos em que a governança de dados atua. A duração e o número de iterações variam por organização.

DAD e SAFe lado a lado

Aspecto	Disciplined Agile / DAD	SAFe
Natureza	Toolkit de decisão: ajuda a escolher e adaptar o modo de trabalho de cada equipe	Framework com papéis, eventos e configurações definidos, em que a organização adota o modelo
Escala	De times pequenos à empresa, com foco em contexto e escolha	Foco em coordenar muitos times em torno de cadeias de valor (ART) e em portfólio
Governança	Governança de apoio: orientar, habilitar e acompanhar equipes por meio de metas de processo	Lean Portfolio Management, guardrails, orçamentos enxutos e conformidade contínua
Dados	Área dedicada (Data Management), com a meta Governar dados e técnicas ágeis de dados	Tratados por enablers, requisitos não funcionais, DoD e arquitetura; versões recentes reforçam gestão de dados curada

Aspecto	Disciplined Agile / DAD	SAFe
Quando se destaca	Quando times de dados precisam adaptar o próprio jeito de trabalhar com liberdade e critério	Quando é preciso sincronizar muitos times e alinhar investimento e entrega ao longo do portfólio

Eles não são excludentes. Muitas organizações combinam elementos: usam a cadência e a coordenação de um modelo em escala e consultam o toolkit de decisão para ajustar o modo de trabalho de times específicos, como as equipes de dados. O importante é **decidir conscientemente**, em vez de aplicar um modelo como cerimônia.

Como a governança de dados funciona de forma ágil

1. Definition of Done de dados

O jeito mais simples de levar a governança ao dia a dia dos times é incluí-la na **definição de pronto**. Assim, nenhuma entrega de dados é considerada concluída sem cumprir o mínimo de governança.

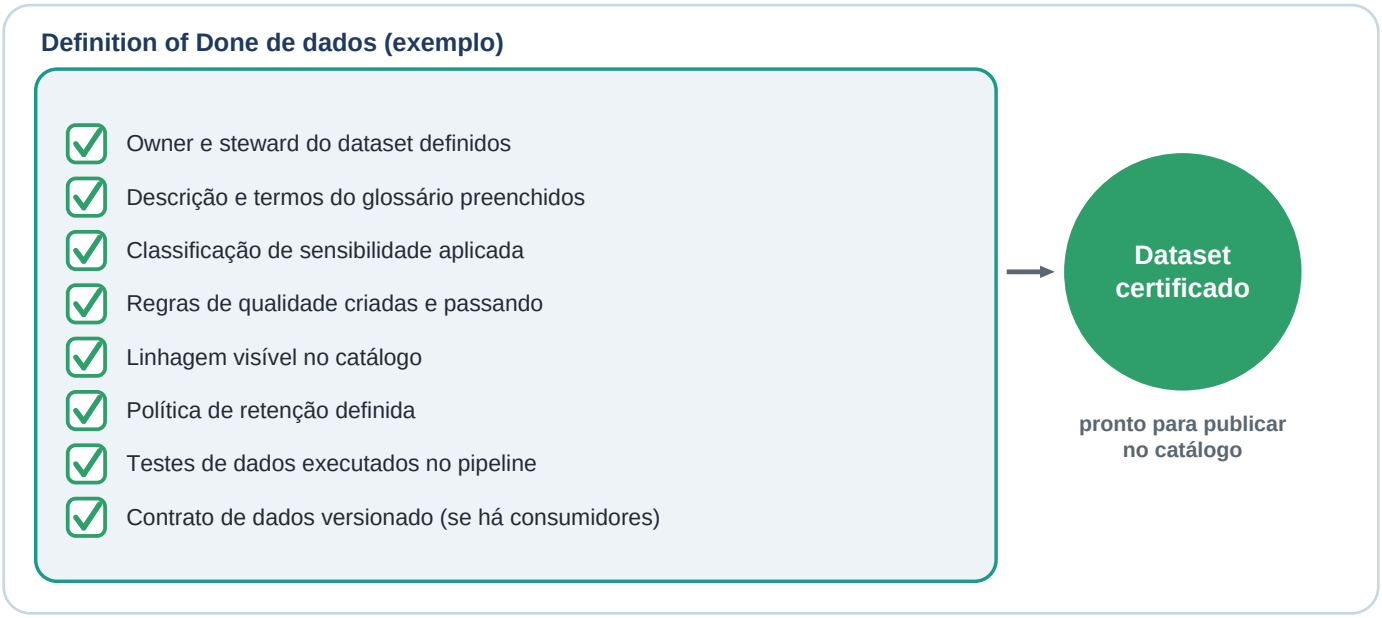


Figura 35 — Exemplo de DoD de dados. O que o time pode verificar automaticamente deve ser verificado automaticamente.

2. Mínimo viável de governança, proporcional ao risco

Em vez de aplicar todas as regras a todo dado, define-se um **mínimo viável** (owner, descrição, classificação) e aumenta-se o rigor conforme a criticidade e a zona do dado (veja o capítulo 3). Dados exploratórios têm poucos controles; produtos de dados consumidos por muita gente têm muitos.

3. Governança embutida na plataforma

Em vez de pedir que cada time implemente controles por conta própria, a plataforma oferece o "caminho pavimentado": modelos de pipeline com testes, classificação automática, catálogo integrado e políticas como código. O time ganha velocidade ao usar o caminho recomendado, e a governança ganha consistência.

4. Stewards próximos dos times e comunidade de prática

Stewards podem ser **embutidos** em times (modelo de proximidade), **por domínio** ou **centrais**. Uma combinação comum é ter stewards próximos do trabalho e uma comunidade de prática que alinha padrões, glossário e boas práticas entre eles. O **owner** participa do refinamento do backlog, para decisões rápidas sobre regras e definições.

5. Backlog de governança e priorização

As necessidades de governança (cobrir linhagem de dados críticos, classificar uma base, criar um glossário) viram itens de backlog e disputam prioridade com o restante. Uma técnica usada no SAFe é o **WSJF (Weighted Shortest Job First)**: prioriza-se pelo custo do atraso dividido pelo tamanho do trabalho. O custo do atraso soma valor para o negócio, criticidade no tempo e redução de risco ou habilitação de oportunidades. Exemplo fictício, com estimativas relativas:

Item do backlog de governança	Valor	Tempo	Risco/oport.	Custo do atraso	Tamanho	WSJF
Classificar dados pessoais do CRM	8	13	13	34	8	4,25
Glossário de termos de vendas	5	3	2	10	3	3,33
Linhagem dos dados críticos do financeiro	13	8	8	29	13	2,23

O item com maior WSJF (aqui, classificar dados pessoais do CRM) entra primeiro. O valor da técnica está em tornar explícito por que um item vem antes do outro.

6. Contratos de dados e testes automatizados

Contratos de dados definem o que o produtor garante (esquema, qualidade, frescor), e os testes automatizados verificam esse acordo a cada mudança. Isso reduz a necessidade de reuniões e revisões manuais, pois o próprio pipeline avisa quando algo quebra a promessa.

Medindo a agilidade da governança

Métricas de fluxo, muito usadas em DevOps (como as quatro métricas do DORA: frequência de implantação, tempo de entrega de mudanças, taxa de falha em mudanças e tempo de recuperação), ajudam a ver se a governança está acelerando ou freando:

Indicador	Como calcular (exemplo)	O que mostra
Tempo para liberar acesso a dados	tempo médio entre a solicitação e a liberação do acesso aprovado	Se a governança é gargalo
Tempo para publicar dataset certificado	tempo entre o início do desenvolvimento e a publicação com DoD cumprido	Fluxo de ponta a ponta
Entregas com DoD de dados cumprido	entregas com todos os itens do DoD / total de entregas de dados	Adoção da governança nos times
Taxa de falha em mudanças de dados	mudanças que causaram incidente de dados / total de mudanças	Qualidade das entregas
Controles automatizados	controles de governança automatizados / total de controles	Maturidade da automação
Participação do owner no refinamento	refinamentos com owner presente / total de refinamentos	Proximidade entre negócio e dados
Incidentes de dados por release	incidentes de dados / número de releases no período	Estabilidade percebida

Roteiro para começar

- **1. Mapear o fluxo atual** de uma entrega de dados, do pedido à publicação, e medir onde há espera (aprovações, filas, retrabalho).
- **2. Definir o mínimo viável** de governança por tipo de dado e zona.
- **3. Incluir o DoD de dados** nos times piloto.
- **4. Automatizar o que mais atrasa** (classificação, testes de qualidade, metadados, liberação de acesso).
- **5. Aproximar stewards e owners** dos times e formar uma comunidade de prática.
- **6. Medir** com poucos indicadores de fluxo e de resultado.
- **7. Inspecionar e adaptar** a cada ciclo: o que ajudou, o que atrapalhou, o que precisa mudar.

Armadilhas comuns

- **Agilidade como desculpa para não ter governança:** ágil não é ausência de regras; é regras mais leves, automáticas e próximas do trabalho.

- **Cerimônia sem mudança:** adotar rituais de DAD ou SAFe sem alterar decisões e fluxo.
- **Fragmentação:** cada time cria seu próprio glossário e suas próprias classificações, sem alinhamento transversal.
- **Stewards sobrecarregados:** alocados em muitos times sem tempo dedicado.
- **Dados como "item de TI":** sem owner de negócio e sem lugar no backlog de produto.
- **Velocidade sem qualidade:** medir só entregas, sem olhar incidentes e retrabalho.
- **Copiar o modelo sem adaptar:** o DAD, em particular, existe justamente para que o contexto guie as escolhas.

Nota sobre as fontes: o capítulo parte de materiais públicos do PMI Disciplined Agile (site, blog e documentação do toolkit) e da Scaled Agile (SAFe). Ambos evoluem por versões (nas fontes consultadas, o Disciplined Agile aparecia em versões 5.x, como a 5.6 de 2022, e o SAFe 6.0 era a referência até o anúncio do AI-Native SAFe em 2026). A aplicação específica a dados e governança é uma proposta deste guia, exceto quando indicado, e não faz parte oficial desses frameworks. Confirme detalhes nos sites oficiais.

9

Monitoramento contínuo da governança

Por que monitorar de forma contínua

Uma governança bem desenhada pode deteriorar em poucos meses: pessoas mudam de área, políticas envelhecem, novas tabelas surgem fora do catálogo, regras de qualidade deixam de rodar. Sem monitoramento, a governança vira uma foto antiga. **Monitoramento contínuo** é a prática de coletar sinais de forma recorrente, compará-los com metas e limites, avisar o responsável certo e registrar o que foi feito. Ele difere de uma **auditoria pontual**, que olha para o passado em um momento específico: o monitoramento detecta a deriva enquanto ela ainda é barata de corrigir.

Os seis domínios deste capítulo seguem o mesmo ciclo (coletar, avaliar, alertar, agir e aprender), mas diferem em fonte de dados, frequência e responsável.

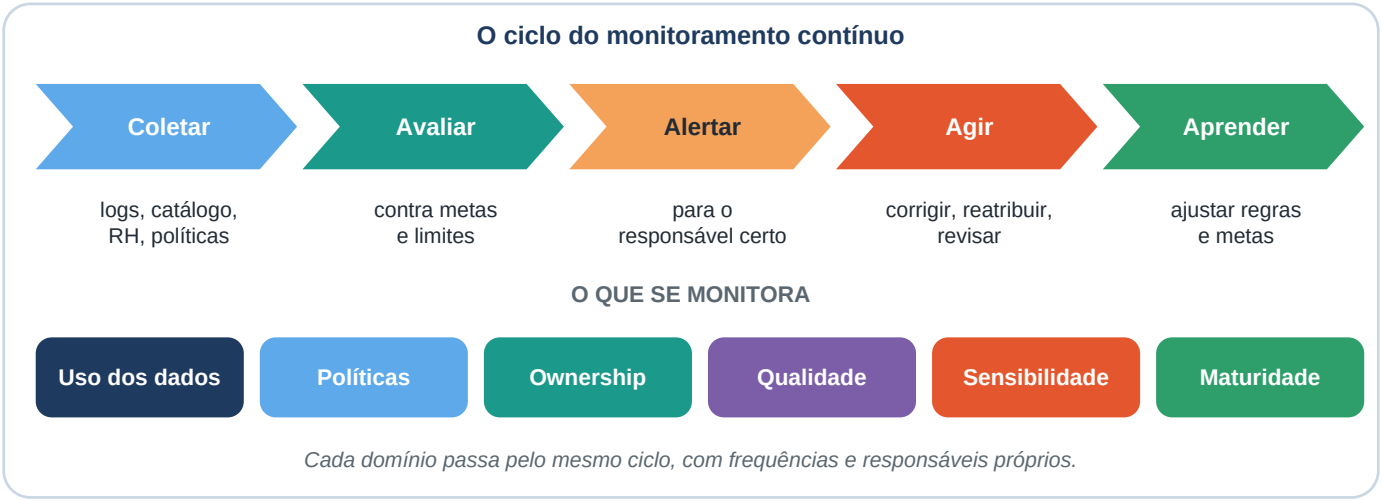


Figura 36 — O ciclo comum a todos os domínios de monitoramento e os seis domínios cobertos.

O mapa do que monitorar

Domínio	Pergunta central	Sinais e fontes	Frequência típica	Quem age
Uso dos dados	Quem usa o quê, com que frequência e com que risco?	Logs de consulta e acesso, atividade do BI, catálogo	Diária a semanal	Custodian, owner, segurança
Políticas	Estão vigentes, revisadas e conhecidas?	Repositório de políticas, datas de revisão, ciências	Mensal; revisão semestral	Escritório de governança
Ownership	Todo ativo crítico tem owner ativo e atual?	Catálogo x sistema de RH, recertificações	Mensal; recertificação trimestral	Owner, steward, comitê
Qualidade	Os dados atendem ao uso e à meta?	Regras, scores, incidentes, observabilidade	Diária a mensal	Steward, custodian, owner
Sensibilidade	A classificação está completa, correta e protegida?	Catálogo, classificadores, controles aplicados	Semanal a mensal	Steward, segurança, DPO
Maturidade	Estamos evoluindo na direção planejada?	Avaliação por dimensão, evidências, roadmap	Semestral ou anual	Comitê, patrocinador

1. Monitoramento do uso dos dados

Saber como os dados são usados responde a três perguntas de governança: **risco** (quem acessa dados sensíveis, e de forma normal?), **valor** (quais dados realmente importam?) e **custo** (o que está parado e pode ser arquivado?). As fontes mais comuns são os logs de consulta do banco ou do warehouse, as trilhas de auditoria e os eventos de atividade da ferramenta de BI (no Power BI, o log de atividades pode ser extraído por meio de APIs administrativas; confirme o que seu tenant permite).

- **Dados sensíveis:** acessos fora do horário, volume incomum, acesso por pessoas ou aplicações novas.
- **Datasets sem uso:** candidatos a arquivamento, com revisão do owner antes de remover.
- **Dados "de sombra":** tabelas, planilhas e relatórios criados fora do catálogo.
- **Revisão periódica de acessos (recertificação):** confirmar se quem tem acesso ainda precisa dele.
- **Finalidade:** acesso concedido para um propósito sendo usado para outro.

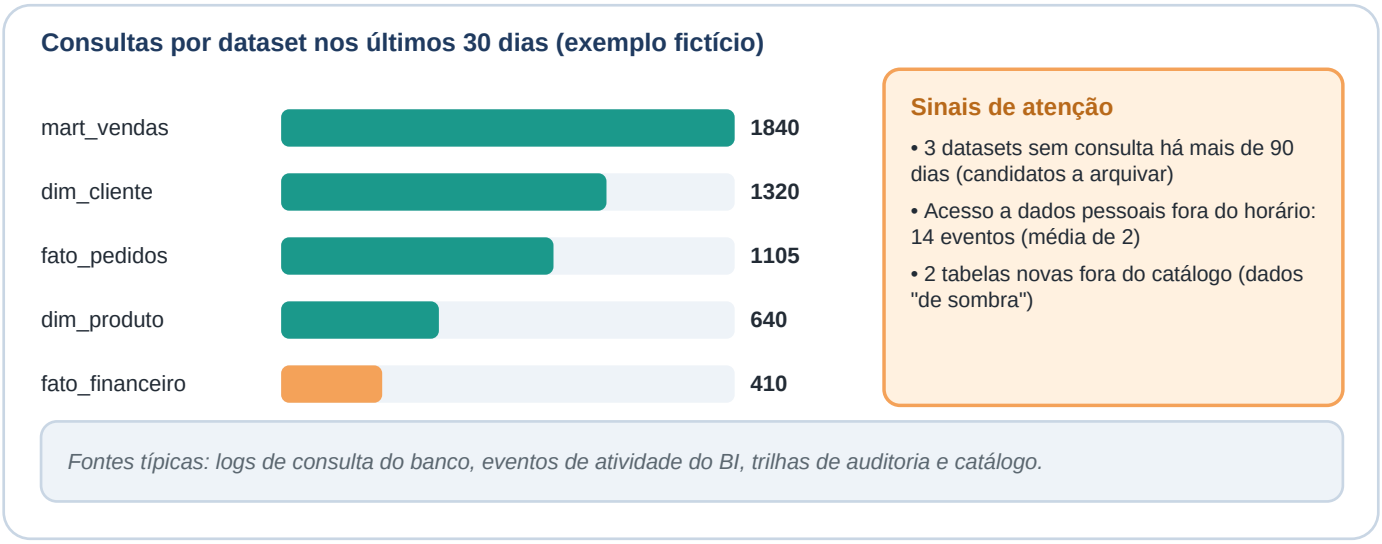


Figura 37 — Exemplo de painel de uso: popularidade por dataset e sinais de atenção. Dados fictícios.

```
-- Datasets sem consulta ha mais de 90 dias (candidatos a arquivar)
SELECT d.dataset, MAX(l.consultado_em) AS ultimo_acesso
FROM catalogo_datasets d
LEFT JOIN log_consultas l ON l.dataset = d.dataset
GROUP BY d.dataset
HAVING MAX(l.consultado_em) IS NULL
    OR MAX(l.consultado_em) < CURRENT_DATE - INTERVAL '90 days';
```

2. Atualização das políticas

Uma política desatualizada é pior que nenhuma: dá falsa sensação de controle. O monitoramento acompanha o **ciclo de vida** de cada política (elaboração, aprovação, publicação, aplicação, revisão e aposentadoria) e dispara revisões por **gatilhos**, não só por calendário.

- **Inventário de políticas** com dono, versão, data de aprovação, vigência e próxima revisão.
- **Alertas de vencimento** com antecedência (por exemplo, 60 e 30 dias).
- **Ciência e comunicação:** registrar que as pessoas afetadas foram informadas.
- **Rastreabilidade:** cada política liga-se a padrões, controles técnicos e evidências. Se não há controle nem evidência, a política é só intenção.
- **Histórico de versões** e justificativa das mudanças.



Figura 38 — Ciclo de vida de uma política, gatilhos de revisão e rastro de evidência.

3. Revisão de ownership

Owners mudam de área, saem da empresa ou acumulam responsabilidades que não conseguem cumprir. O resultado é o **dado órfão**: existe, é usado, mas ninguém decide sobre ele. A revisão periódica combina dois mecanismos: **gatilhos de evento** (desligamento ou mudança de área vindos do RH) e **recertificação periódica**, em que o owner confirma que continua responsável.

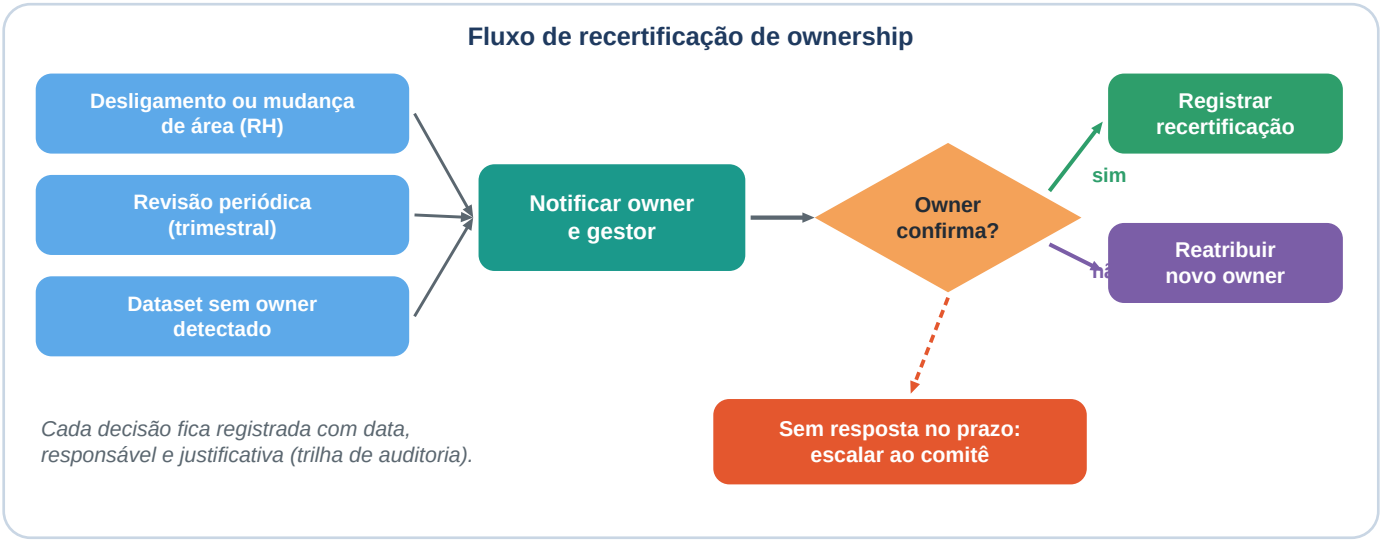


Figura 39 — Fluxo de recertificação. A decisão não respondida no prazo escala para o comitê.

```
-- Datasets cujo owner esta ausente ou nao esta mais ativo no RH
SELECT d.dataset, d.owner_email
FROM catalogo_datasets d
LEFT JOIN rh_colaboradores r
       ON r.email = d.owner_email AND r.status = 'ativo'
WHERE d.owner_email IS NULL OR r.email IS NULL;
```

- **Indicadores:** cobertura de owner e de steward, owners órfãos, recertificações vencidas e tempo médio para reatribuir.
- **Sucessão:** toda atribuição tem um substituto designado.
- **Carga:** verificar se uma pessoa acumula owners demais, o que indica papel só de nome.

4. Acompanhamento da qualidade

Os mecanismos de qualidade já foram descritos no capítulo 6. No monitoramento, o foco é **acompanhar tendência e priorizar**. Uma técnica útil é o **gráfico de controle**, que mostra a média e limites de variação normal do score: pontos dentro da faixa são ruído; pontos fora dela, ou sequências longas em uma direção, indicam mudança real

que merece investigação.

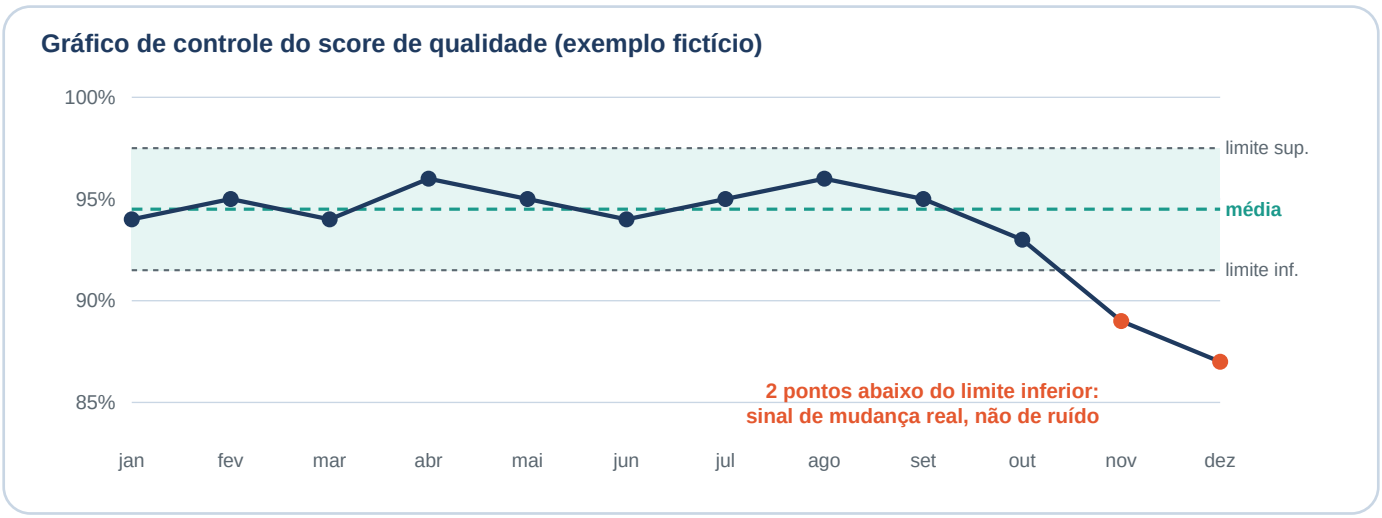


Figura 40 — Gráfico de controle do score de qualidade. Os dois últimos pontos saem do limite inferior e pedem investigação.

- **Priorizar por criticidade e uso:** monitore mais de perto o que alimenta decisões importantes e é muito consumido.
- **Limites que evoluem:** revise os limites quando o processo melhora ou o uso muda.
- **Incidentes:** acompanhar abertos, idade, reincidência e tempo de resolução por severidade.
- **Alertas com dono:** todo alerta tem responsável, prazo e instrução de resposta (runbook).

5. Classificação de sensibilidade

Classificar não basta: é preciso **manter** a classificação correta e **conferir se os controles acompanham** o rótulo. Os principais pontos de monitoramento:

- **Cobertura:** percentual de colunas e datasets classificados, com atenção especial a objetos novos.
- **Acurácia:** amostragem por humanos para medir erros de classificadores automáticos (falsos positivos e falsos negativos).
- **Deriva:** colunas novas ou mudança de conteúdo que alteram a sensibilidade (por exemplo, um campo livre que passa a receber CPF).
- **Coerência com controles:** dado pessoal sem mascaramento, dado sensível em zona aberta, retenção ausente.
- **Propagação:** a classificação acompanha as colunas derivadas pela linhagem (capítulo 5).

Matriz de lacunas: sensibilidade x controles aplicados (exemplo fictício)

Classificação	Acesso restrito	Mascaramento	Criptografia	Retenção definida	Auditoria de acesso
Pública	n/a	n/a	n/a	OK	n/a
Interna	OK	n/a	OK	OK	n/a
Confidencial	OK	OK	OK	Lacuna	OK
Pessoal	OK	OK	OK	Lacuna	OK
Pessoal sensível	OK	Lacuna	OK	OK	Lacuna

O rótulo "Lacuna" aparece em texto, além da cor. **3 lacunas em dados confidenciais, pessoais e sensíveis exigem ação**

Figura 41 — Matriz de lacunas entre o nível de sensibilidade e os controles aplicados. A lacuna aparece em texto, não só em cor.

```
-- Colunas pessoais ou sensiveis sem mascaramento registrado
SELECT c.tabela, c.coluna, c.classificacao
FROM catalogo_colunas c
LEFT JOIN controles_mascaramento m
       ON m.tabela = c.tabela AND m.coluna = c.coluna
WHERE c.classificacao IN ('PESSOAL', 'PESSOAL_SENSIVEL')
  AND m.coluna IS NULL;
```

6. Evolução da maturidade

A avaliação de maturidade mostra se o programa está progredindo e onde investir. Para evitar autoavaliações otimistas, use **critérios descritos por nível** e **evidências** (documentos, registros, métricas) e faça revisão cruzada entre avaliadores. Repita em intervalos fixos (semestral ou anual) e compare com a avaliação anterior e com a meta.

- Escolha 6 a 10 dimensões (por exemplo: estratégia, papéis, políticas, metadados, qualidade, privacidade, segurança e cultura).
- Defina o nível alvo por dimensão, de acordo com o risco e o valor, e não "5 em tudo".
- Associe cada salto de nível a iniciativas do roadmap e a OKRs.
- Acompanhe o **delta** em relação ao período anterior.

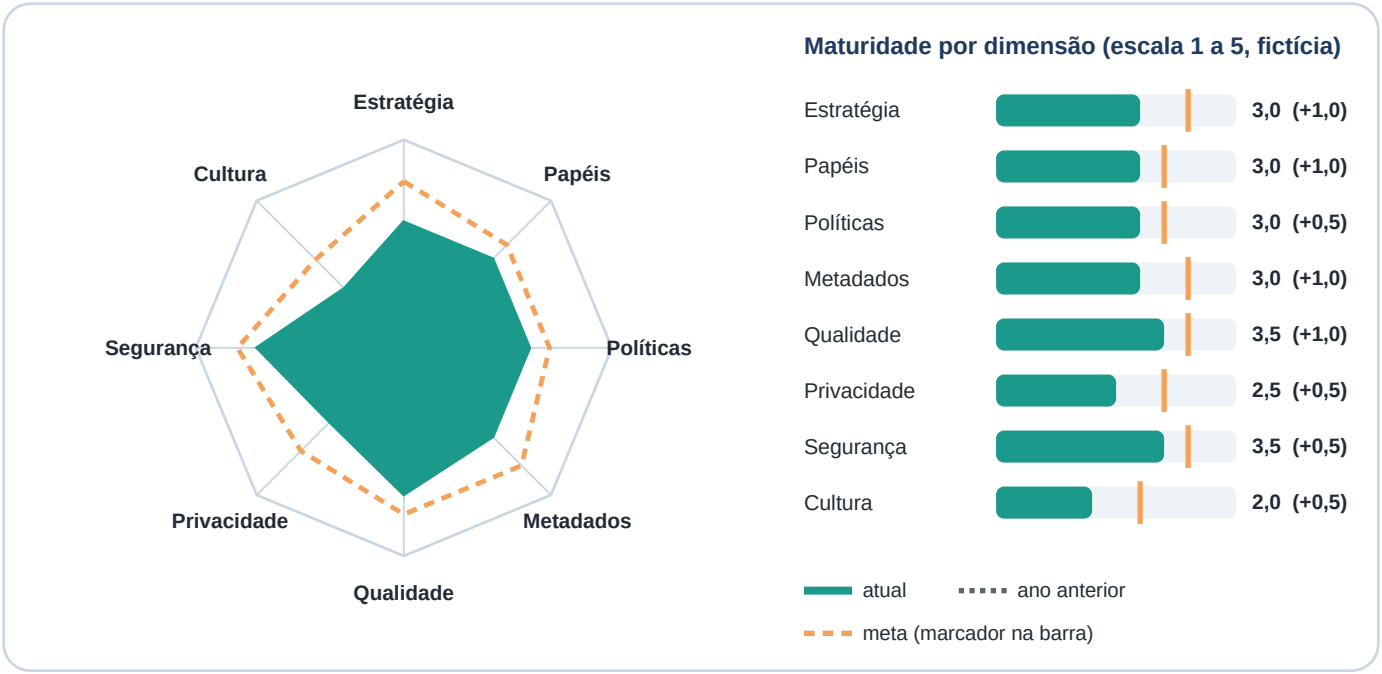


Figura 42 — Maturidade por dimensão: ano anterior, situação atual e meta. O radar mostra a forma geral; as barras mostram o detalhe.

Arquitetura e cadência do monitoramento

Para o monitoramento ser sustentável, os dados precisam chegar de forma **automática** a uma camada de métricas com definições consistentes. Isso evita que cada painel recalcule o mesmo indicador de um jeito diferente.

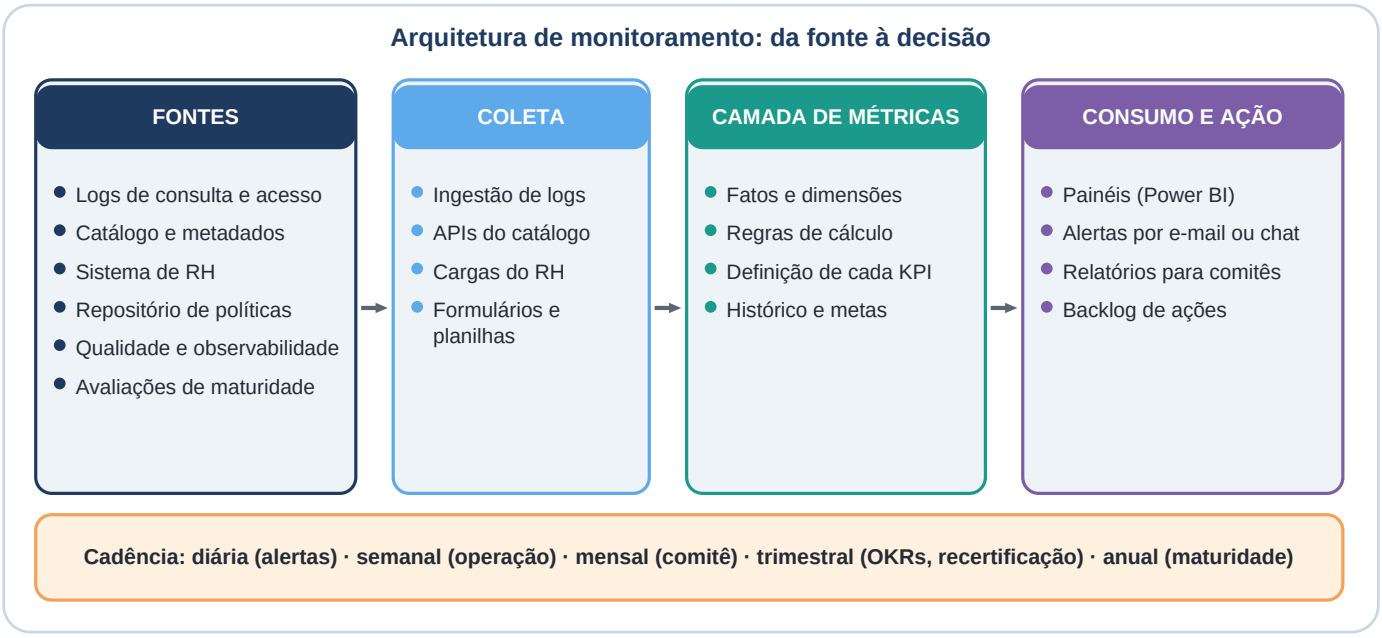


Figura 43 — Fluxo de dados do monitoramento e a cadência de revisão.

Cadência	Fórum ou rotina	O que se revisa
Diária	Alertas operacionais	Incidentes de qualidade, acessos anômalos, falhas de pipeline
Semanal	Reunião operacional dos stewards	Backlog de ações, SLAs, itens críticos em aberto
Mensal	Comitê de governança	Painel de KPIs, tendências, decisões e escalonamentos
Trimestral	Revisão de OKRs e recertificação	Progresso dos resultados-chave, ownership e acessos
Semestral	Revisão de políticas	Vencimentos, gatilhos e mudanças regulatórias
Anual	Avaliação de maturidade	Evolução por dimensão, metas e roadmap

Indicadores por domínio de monitoramento

Domínio	Indicador	Como calcular (exemplo)	Polaridade
Uso	Datasets sem consulta em 90 dias	datasets sem acesso em 90 dias / total de datasets	Menor é melhor
Uso	Acessos anômalos a dados sensíveis	eventos fora do padrão / total de acessos a dados sensíveis	Menor é melhor
Políticas	Políticas dentro do prazo de revisão	políticas revisadas no prazo / total de políticas	Maior é melhor
Políticas	Políticas com controle e evidência	políticas com controle e evidência vinculados / total	Maior é melhor
Ownership	Cobertura de owner ativo	datasets com owner ativo no RH / total de datasets	Maior é melhor
Ownership	Recertificações vencidas	recertificações vencidas / recertificações devidas	Menor é melhor
Qualidade	Score por domínio	média ponderada das regras (capítulo 6)	Maior é melhor
Qualidade	Tempo de resolução de incidentes	tempo médio entre detecção e correção	Menor é melhor
Sensibilidade	Cobertura de classificação	colunas classificadas / total de colunas	Maior é melhor
Sensibilidade	Lacunas de controle	colunas sensíveis sem controle exigido / total de colunas sensíveis	Menor é melhor
Maturidade	Nível médio e delta anual	média dos níveis por dimensão; variação ante o ano anterior	Maior é melhor

Alertas e resposta

- **Severidade:** defina o que é crítico, alto, médio e baixo, com prazo de resposta para cada nível.
- **Dono e runbook:** quem recebe, o que fazer e como registrar.
- **Agrupamento:** consolidar alertas relacionados para evitar enxurrada.
- **Revisão dos alertas:** desligar ou ajustar os que nunca levam a ação.
- **Fechamento do ciclo:** toda lição aprendida vira ajuste de regra, política ou meta.

Armadilhas comuns

- **Medir muito e agir pouco:** painéis sem dono nem rotina de decisão.
- **Coleta manual:** planilhas alimentadas por e-mail, que atrasam e geram erros.
- **Definições divergentes:** o mesmo KPI calculado de formas diferentes em painéis diferentes.
- **Fadiga de alertas:** limites apertados demais ou sem priorização.
- **Maturidade como nota:** perseguir o número em vez de evoluir de fato.
- **Ignorar a privacidade do monitoramento:** logs de acesso também contêm dados pessoais e precisam de controle, finalidade e retenção definidos.

> **Conexão com o seu dashboard:** os seis domínios deste capítulo formam uma boa estrutura de páginas para o seu relatório. O capítulo seguinte mostra exemplos de visuais e um modelo de dados de apoio para montá-lo.

10

Visuais para acompanhar KPIs e OKRs

Para que servem os exemplos deste capítulo

O monitoramento só funciona se as pessoas conseguem **enxergar, entender e agir** sobre os indicadores. Este capítulo de apoio reúne exemplos de visuais para acompanhar os KPIs e os OKRs da área de governança, com sugestões de como montá-los no Power BI. Os painéis mostrados são **desenhos de referência com dados fictícios**, não relatórios prontos.

KPI, OKR e tipos de indicador

Conceito	O que é	Exemplo em governança de dados
KPI (indicador-chave de desempenho)	Mede de forma contínua a saúde de um processo ou resultado, com meta e periodicidade	Score de qualidade dos dados críticos: 94,8% (meta 95%)
OKR (objetivos e resultados-chave)	Objetivo qualitativo e ambicioso, ligado a poucos resultados-chave mensuráveis, em um ciclo de tempo (normalmente trimestral)	Objetivo: tornar os dados críticos confiáveis e rastreáveis. KR: subir a linhagem ponta a ponta de 40% para 85%
Métrica	Qualquer medida, sem necessariamente ter meta	Número de consultas por dataset

Convém distinguir os **tipos de indicador**: de **resultado** (o que se quer alcançar, como o score de qualidade), de **atividade** (o que foi feito, como o número de reuniões) e de **cobertura** (o quanto está sendo medido ou tratado, como o percentual de colunas com regras). Um bom painel combina os três, com ênfase em resultado. Os KPIs são o termômetro permanente; os OKRs são o foco do trimestre, e é comum que os resultados-chave sejam KPIs com meta de mudança.

Princípios de design

- **Conheça o público:** executivos querem poucos números e a direção; gestores querem tendências e comparação; operação quer a lista do que fazer.
- **Hierarquia de leitura:** resumo no topo, tendência no meio, detalhe embaixo ou por drill-through.
- **Sempre dê contexto:** meta, período anterior e variação ao lado do valor.
- **Cor com significado e com redundância:** use texto, ícone ou posição além da cor (pessoas com daltonismo e impressões em preto e branco).
- **Um visual, uma pergunta:** evite combinar muitas mensagens em um gráfico.
- **Menos é mais:** remova grades, bordas e efeitos que não informam; evite gráficos 3D e rosca com muitas fatias.
- **Definição à mão:** cada KPI deve ter fórmula, fonte, polaridade e dono visíveis (por tooltip ou página de glossário).

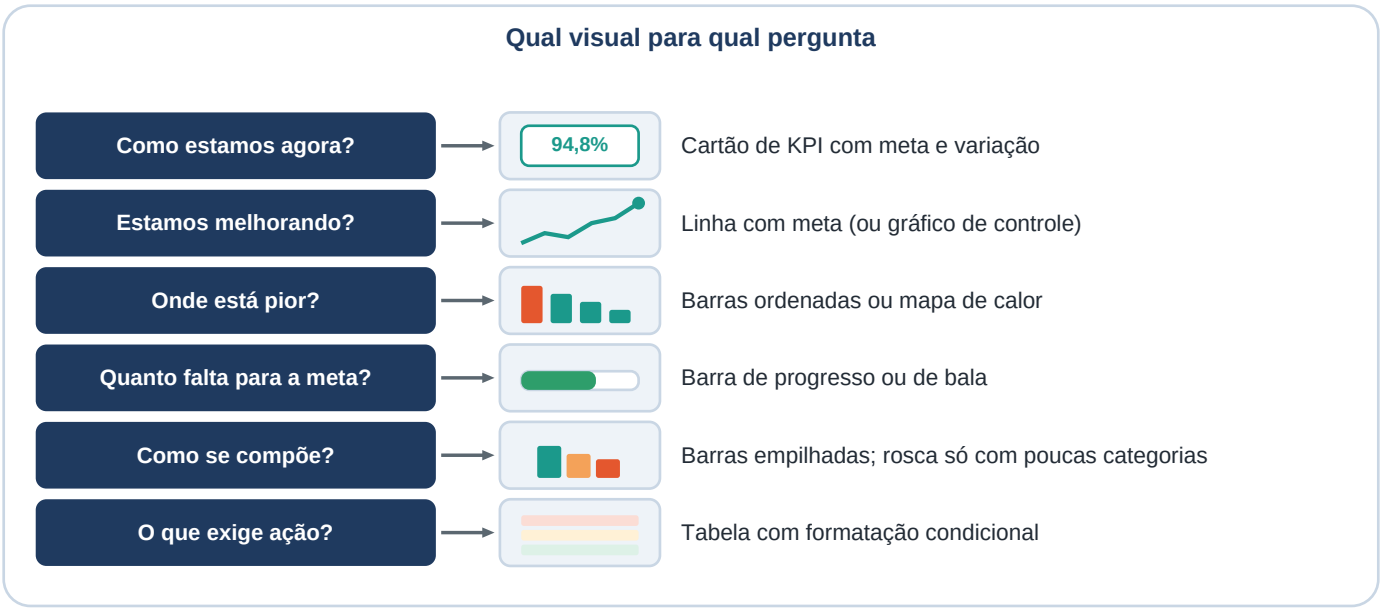


Figura 44 — Guia rápido de escolha de visual. Escolha pela pergunta que o público precisa responder.

Catálogo de visuais com exemplos

1. Cartões de KPI

O elemento mais usado em painéis executivos. Cada cartão traz o valor atual, a meta, a variação em relação ao período anterior, um minigráfico de tendência e um status em texto.

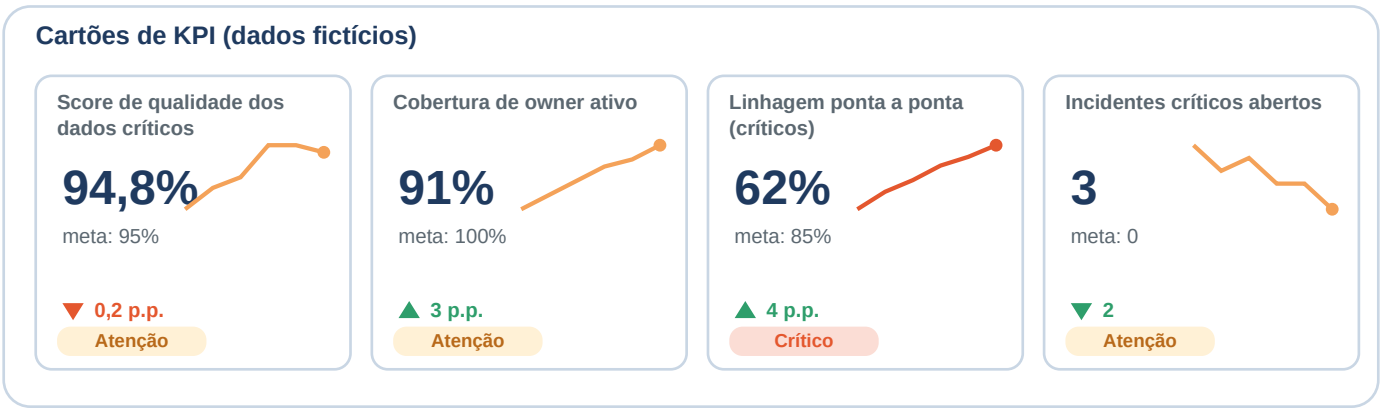


Figura 45 — Quatro cartões de KPI. A seta e a cor da variação dependem da polaridade do indicador (para incidentes, descer é bom).

2. Painel de OKR

Mostra o objetivo e, para cada resultado-chave, o ponto de partida, o valor atual, a meta, o **progresso percentual** e um nível de **confiança** declarado pelo responsável. O progresso é calculado sobre a distância entre início e meta, o que funciona tanto para indicadores que sobem quanto para os que descem.

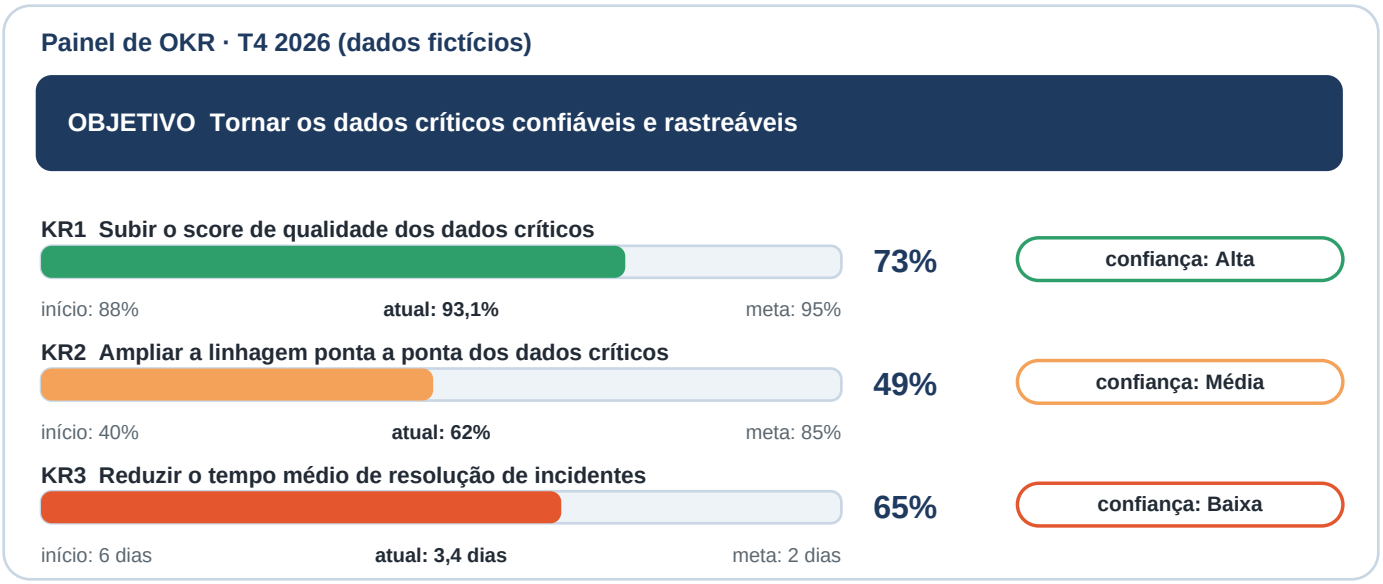


Figura 46 — Painel de OKR com três resultados-chave. A confiança é um julgamento do responsável, e complementa o percentual de progresso.

3. Tendência com meta

Mostra se o indicador está melhorando e há quanto tempo. A linha de meta e anotações de eventos (nova regra, mudança de processo) ajudam a interpretar quedas e saltos. Para variações normais x anormais, use o gráfico de controle do capítulo 9.

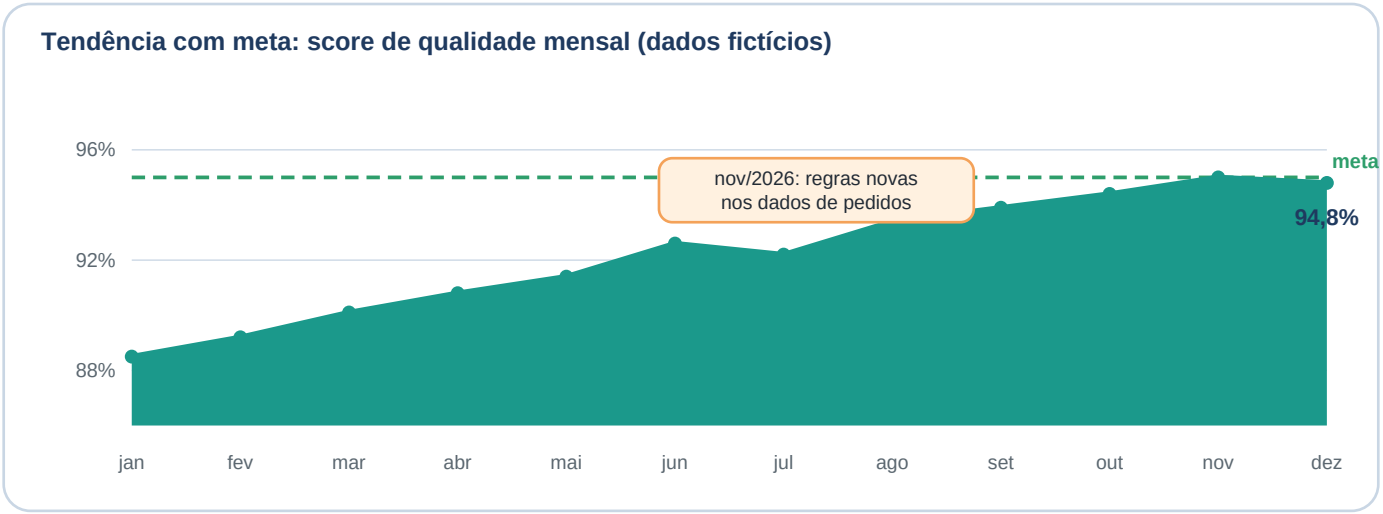


Figura 47 — Linha com meta e evento anotado. O valor final é rotulado diretamente.

4. Mapa de calor por domínio e indicador

Responde "onde está pior?" em uma só imagem. No Power BI, usa-se uma **matriz** com formatação condicional de cor de fundo. Mantenha os números visíveis nas células.

Mapa de calor: domínios x indicadores, em % (dados fictícios)

Domínio	Qualidade	Metadados	Linhagem	Owner ativo	Classificação
Cliente	96%	88%	70%	100%	98%
Produto	90%	82%	55%	95%	91%
Financeiro	98%	94%	85%	100%	99%
Pedidos	82%	70%	48%	90%	76%
RH	88%	60%	30%	85%	94%

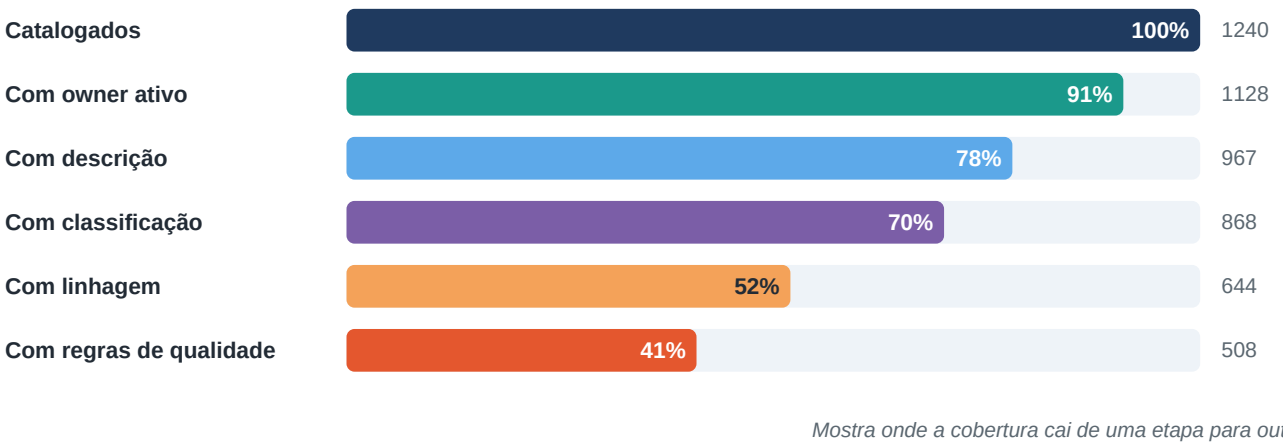
90% ou mais · 75% a 89% · abaixo de 75% — *Os valores aparecem nas células, além da cor.*

Figura 48 — Matriz de calor. A ordenação por linha ou coluna ajuda a achar os piores pontos.

5. Cobertura em cascata

Mostra quanto do inventário cumpre cada etapa de governança (owner, descrição, classificação, linhagem, regras). A queda entre etapas revela onde está o gargalo.

Cobertura em cascata do catálogo (1.240 datasets, dados fictícios)



Mostra onde a cobertura cai de uma etapa para outra

Figura 49 — Cobertura em cascata. Cada barra é um percentual do total de datasets catalogados.

6. Maturidade: atual x meta

O gráfico de halteres (dumbbell) compara dois valores por categoria e costuma ser mais legível que o radar quando há muitas dimensões. No Power BI, pode ser aproximado com um gráfico de dispersão ou de linhas com marcadores, ou com um visual personalizado.

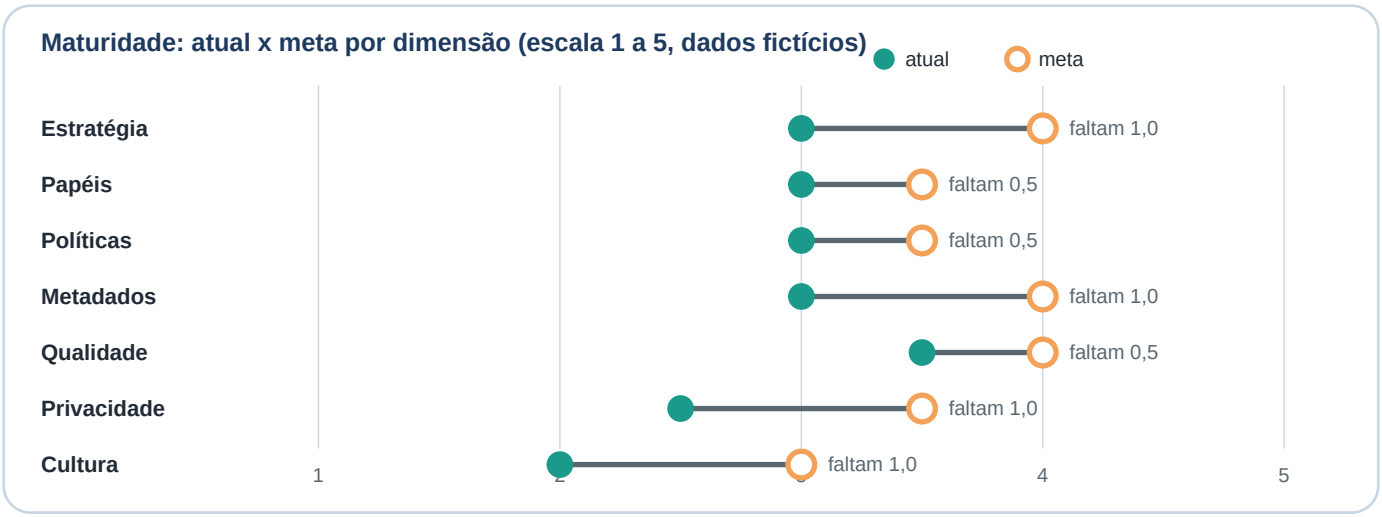


Figura 50 — Halteres de maturidade. A distância entre os pontos é o que falta para a meta.

7. Incidentes por idade e severidade

Barras empilhadas mostram o volume e a antiguidade dos incidentes abertos. Barras altas à direita (itens antigos) indicam acúmulo e risco de estourar o SLA.

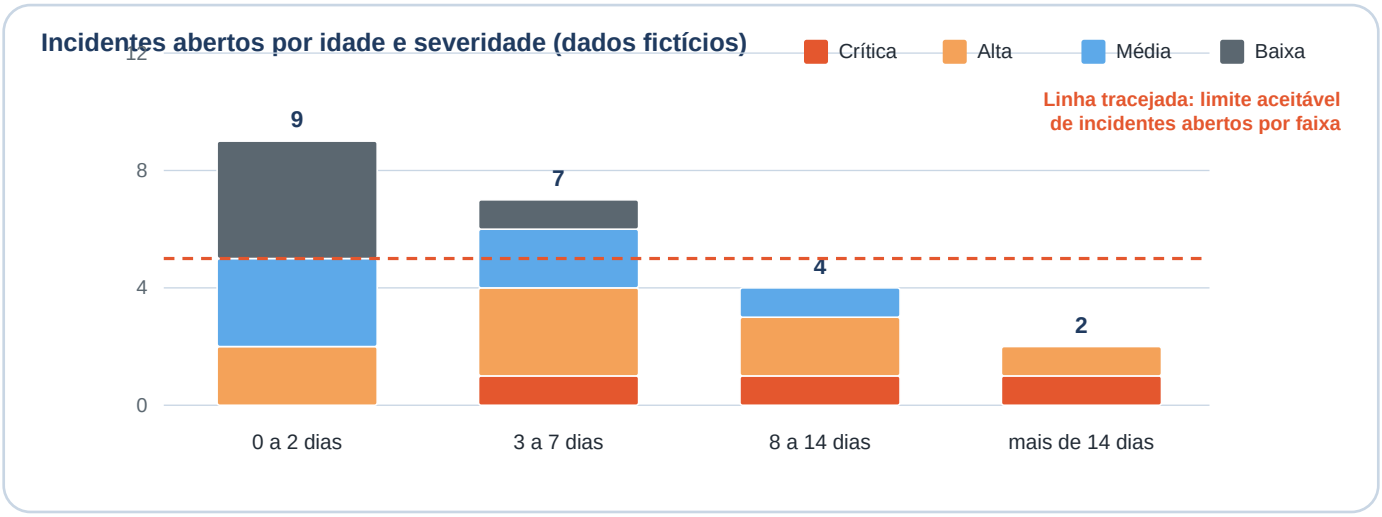


Figura 51 — Incidentes abertos por faixa de idade, empilhados por severidade.

8. Status de ownership

A rosca vale aqui porque há poucas categorias. Ao lado, uma lista com os itens que exigem ação transforma o indicador em tarefa.

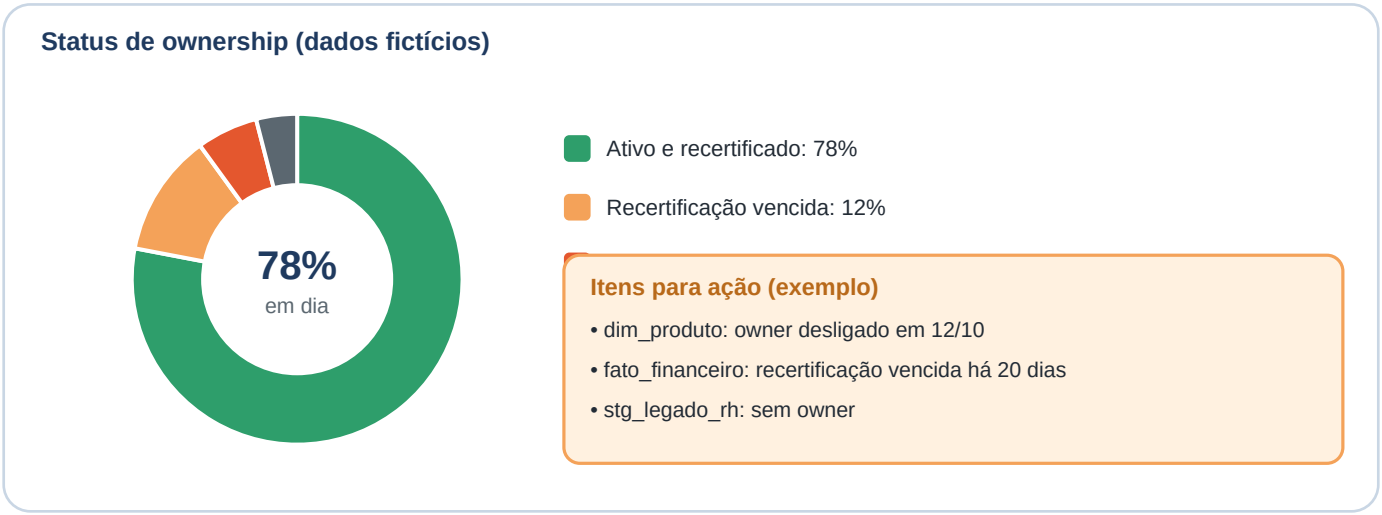


Figura 52 — Rosca de status de ownership e lista de itens para ação.

Composição de painéis completos

Com os blocos acima, monta-se um painel por público. O exemplo executivo prioriza poucos números, tendência e progresso dos OKRs; o operacional prioriza a lista de ações e os prazos.



Figura 53 — Exemplo de visão executiva (dados fictícios): cartões, tendência, OKRs e mapa de calor reduzido.

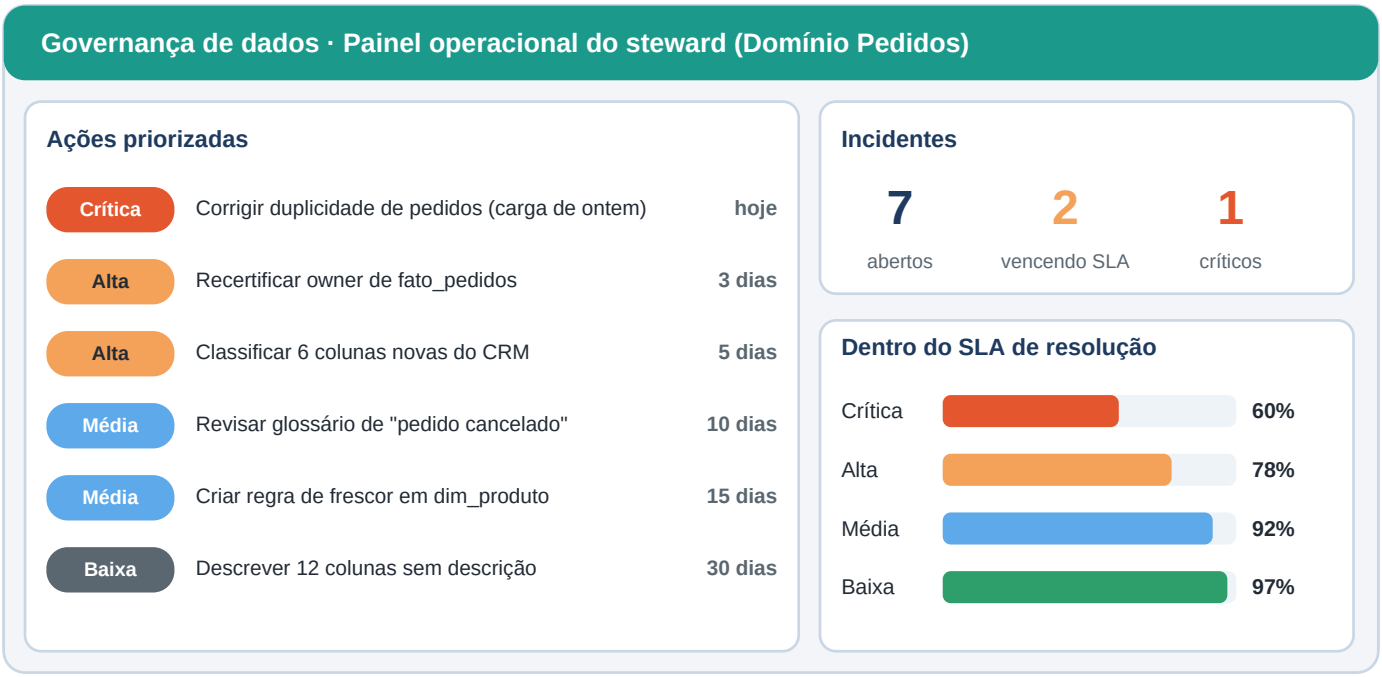


Figura 54 — Exemplo de painel operacional do steward (dados fictícios): ações priorizadas, incidentes e SLA.

Páginas sugeridas para o relatório

Página	Público	Visuais principais	Perguntas que responde
1 · Visão executiva	Diretoria, patrocinador	Cartões de KPI, tendência, OKRs, calor por domínio	Estamos melhorando? Onde atuar?
2 · OKRs	Comitê, liderança	Painel de OKR, progresso e confiança	Vamos atingir os resultados do trimestre?
3 · Qualidade	Stewards, owners	Tendência, gráfico de controle, incidentes por idade	Quais domínios pioraram? Há incidentes antigos?
4 · Metadados e linhagem	Engenharia, stewards	Cascata de cobertura, tabela de lacunas	O que falta documentar e rastrear?
5 · Ownership e políticas	Comitê, escritório de governança	Rosca de ownership, políticas a vencer	Quem está sem owner? O que vence?
6 · Sensibilidade e privacidade	DPO, segurança	Matriz de lacunas, cobertura de classificação	Há dado sensível sem controle?
7 · Uso dos dados	Custodians, segurança	Popularidade, datasets sem uso, acessos anômalos	O que é usado e o que está parado?
8 · Maturidade	Comitê, patrocinador	Halteres ou radar, roadmap	Estamos evoluindo no ritmo planejado?
9 · Operação	Stewards	Lista de ações, SLA, incidentes	O que preciso fazer hoje?
10 · Glossário de KPIs	Todos	Tabela com definição, fórmula, fonte e dono	O que cada número significa?

Visuais do Power BI e cuidados

Exemplo	Visual no Power BI	Cuidados
Cartão de KPI	Cartão, cartão de várias linhas ou visual KPI; minigráfico por visual personalizado ou combinação	Defina polaridade por indicador; mostre status em texto
Painel de OKR	Barras (empilhadas ou com marcador) e tabela com formatação condicional	Calcule progresso com início e meta; barra de bala exige visual personalizado
Tendência com meta	Gráfico de linhas com linha constante ou medida de meta	Eixo com base honesta; anotações com texto
Mapa de calor	Matriz com formatação condicional de cor de fundo	Números visíveis; faixas de cor documentadas
Cascata de cobertura	Funil ou barras horizontais	Base clara (total de datasets); mesma unidade em todas as barras
Halteres de maturidade	Dispersão ou linhas com marcadores; visual personalizado	Escala igual para todas as dimensões
Incidentes por idade	Colunas empilhadas	Ordenar as faixas por idade; linha de limite
Rosca de ownership	Rosca	Poucas categorias; rótulos diretos

Modelo de dados de apoio

Um modelo em **estrela** mantém os cálculos consistentes. Uma tabela de fatos com a medida diária por indicador e domínio, ligada a dimensões de data, indicador, domínio, dataset e pessoa, permite reaproveitar os mesmos cálculos em todas as páginas. Os eventos (incidentes e acessos) ficam em fatos próprios que usam as mesmas dimensões.

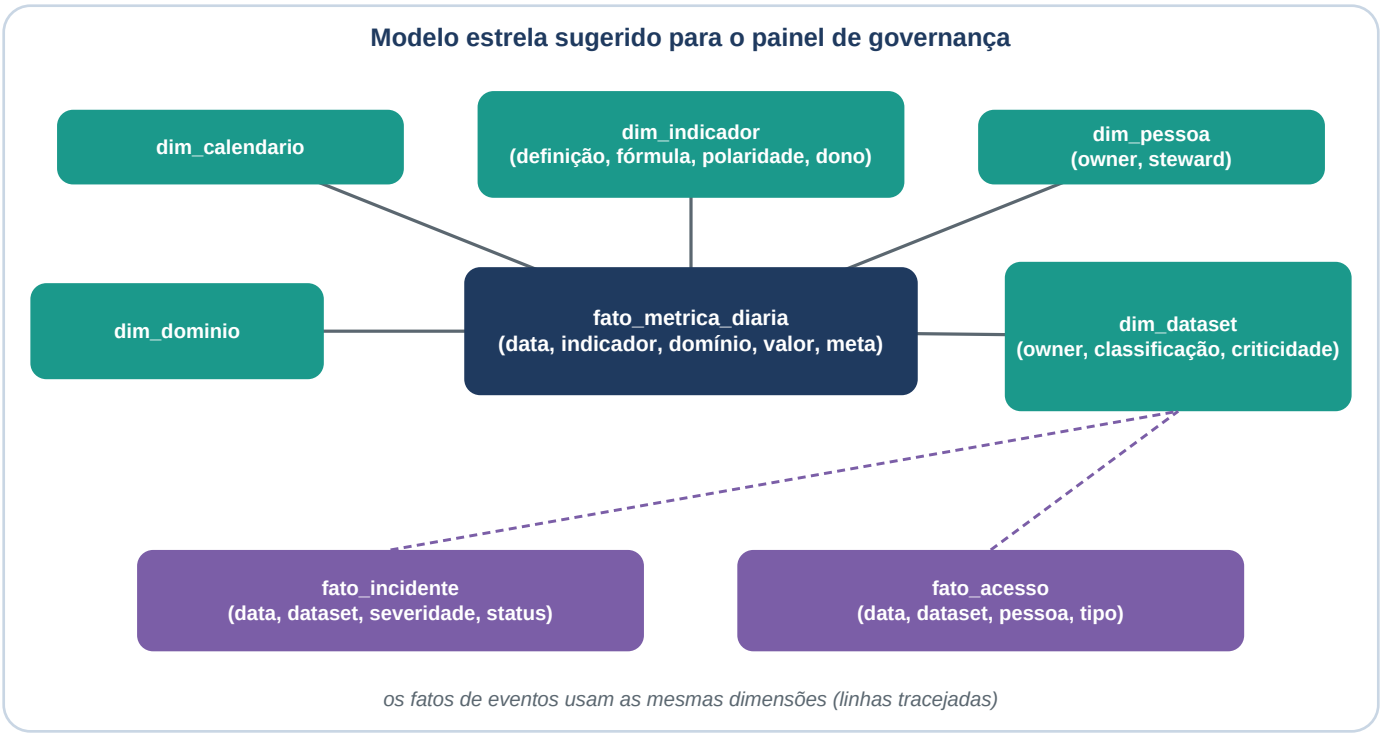


Figura 55 — Modelo estrela sugerido. A dimensão de indicador guarda definição, fórmula, polaridade e dono, o que alimenta o glossário de KPIs.

Exemplos de medidas em DAX

```
Score Qualidade =
    DIVIDE ( SUM ( fato_qualidade[regras_ok] ), SUM ( fato_qualidade[regras_avaliadas] ) )

Variacao Mes =
    [Score Qualidade]
        - CALCULATE ( [Score Qualidade], DATEADD ( dim_calendario[data], -1, MONTH ) )

Status =
    SWITCH ( TRUE (),
        [Score Qualidade] >= [Meta], "No alvo",
        [Score Qualidade] >= [Meta] - 0.05, "Atencao",
        "Critico" )

Cobertura Owner =
    DIVIDE (
        CALCULATE ( COUNTROWS ( dim_dataset ), dim_dataset[owner_email] <> BLANK () ),
        COUNTROWS ( dim_dataset )
    )

Progresso KR =
    MAX ( 0, MIN ( 1, DIVIDE ( [Valor Atual] - [Valor Inicial], [Meta] - [Valor Inicial] ) ) )
```

O cálculo do progresso do KR usa a distância entre início e meta, então serve para indicadores que sobem e que descem. As medidas acima são exemplos genéricos: ajuste nomes de tabelas e colunas ao seu modelo.

Boas práticas de construção

- **Dicionário de KPIs no modelo:** uma tabela com nome, definição, fórmula, fonte, polaridade, meta, dono e periodicidade, exibida em uma página de glossário.
- **Fonte única de cálculo:** as medidas ficam no modelo semântico e são reaproveitadas em todos os relatórios.
- **Segurança por linha (RLS):** restrinja o que cada domínio vê quando houver dados sensíveis ou gestão distribuída.
- **Atualização:** alinhe a frequência de atualização com a cadência do indicador (diária para incidentes, mensal para maturidade).
- **Navegação:** marcadores, botões e drill-through para ir do resumo ao detalhe, sem poluir a página.

- **Tooltips de página:** mostram a definição do KPI e uma mini tendência ao passar o mouse.
- **Acessibilidade:** texto alternativo nos visuais, contraste adequado, ordem de tabulação lógica e títulos descritivos.
- **Desempenho:** poucos visuais por página, modelo enxuto e agregações quando houver muito volume.

Checklist de revisão do painel

- Cada KPI tem definição, fórmula, fonte, dono, meta e polaridade documentadas?
- O visual responde a uma pergunta clara do público?
- Há contexto (meta, período anterior, variação) ao lado dos números?
- O significado das cores é explicado, e o status também aparece em texto?
- Os números batem com a fonte (reconciliação feita)?
- A página mais importante cabe em uma tela e se entende em cerca de cinco segundos?
- Há um responsável e uma rotina de decisão para cada alerta do painel?
- O público-alvo validou que os visuais ajudam nas decisões dele?

Próximo passo: traga o dashboard que você criou (prints ou export) e sua lista de KPIs. Posso compará-lo com estes exemplos, apontar visuais que não respondem a uma pergunta clara, indicadores de atividade que poderiam virar resultado e lacunas em relação aos seis domínios de monitoramento.

Conectando tudo com o dashboard de KPIs

Quando você trouxer o dashboard para validação, este quadro funciona como roteiro. Marque o que já existe e o que falta.

Capítulo	Pergunta de validação	Indicadores candidatos
1 · Introdução	O dashboard mostra resultado (confiança, risco, valor) ou só atividade?	Domínios com owner e steward; políticas revisadas no prazo; maturidade
2 · Governança e gestão	Cada indicador tem responsável e um fórum que o acompanha?	Incidentes por severidade; tempo de resolução; decisões do comitê
3 · Big Data e Normal Data	Os controles são proporcionais à zona e à criticidade?	Datasets do lake com metadados mínimos; % classificado na ingestão
4 · Metadados	A documentação é completa, viva e usada?	Coberturas de descrição, glossário, owner e classificação; adoção do catálogo
5 · Linhagem	Os dados críticos têm linhagem de ponta a ponta e ela é confiável?	Cobertura ponta a ponta; frescor e precisão validada; mudanças com análise de impacto
6 · Qualidade	Os KPIs medem resultado ou só cobertura de regras?	Score por domínio; MTTD e MTTR; reincidência; regras em dados críticos
7 · Ética e privacidade	Há visibilidade sobre dados pessoais e novos usos revisados?	Dados pessoais mapeados; solicitações de titulares no prazo; usos avaliados
8 · Agilidade	A governança acelera ou freia as entregas?	Tempo de liberação de acesso; entregas com DoD cumprido; falha em mudanças; controles automatizados
9 · Monitoramento	Os seis domínios são monitorados com dono, cadência e ação?	Datasets sem uso; políticas no prazo; owners ativos; lacunas de controle; delta de maturidade
10 · Visuais de KPIs e OKRs	Cada visual responde a uma pergunta do público?	Cartões com meta e variação; progresso dos OKRs; mapa de calor por domínio; glossário de KPIs

Referências públicas para aprofundar

- **DAMA-DMBOK (2ª edição):** áreas de governança, metadados, qualidade e integração.
- **Lei Geral de Proteção de Dados (Lei 13.709/2018)** e materiais orientativos da ANPD.
- **ISO/IEC 25012:** modelo de qualidade de dados. **ISO/IEC 11179**, **Dublin Core** e **DCAT**: padrões de metadados.
- **OpenLineage:** padrão aberto de linhagem. **Modelos de maturidade:** DCAM e CMMI-DMM.
- **Data mesh:** trabalhos de Zhamak Dehghani. **Governança não invasiva:** trabalhos de Robert S. Seiner.
- **PMI Disciplined Agile:** site do toolkit, DA Browser e blog (incluindo as páginas de Data Management), e o livro *Disciplined Agile Delivery*, de Scott Ambler e Mark Lines.
- **SAFe:** framework.scaledagile.com, com os materiais de Lean Portfolio Management, Agile Release Train e as novidades do AI-Native SAFe.
- **DORA:** pesquisa e métricas de desempenho de entrega de software.

Quando terminar de ler, traga o dashboard em Power BI (prints ou export) com a definição de cada KPI. Posso avaliá-lo à luz de todos os capítulos, e também aprofundar os temas que ainda não tiveram capítulo próprio (LGPD, CDO, PMBOK e DMBOK, dados como ativos e políticas).